Finanzas Computacionales

UCEMA - 2026



Entrega 3: Implementación del backtest y resultados preliminares

Pronóstico de volatilidad del S&P 500 aplicado a una estrategia de volatility targeting

Alumnos: Andrés Otero y Ezequiel Telias

1. Implementación del backtest

El pipeline completo está implementado y corre de punta a punta desde el snapshot congelado de datos hasta las tablas finales, con todos los resultados versionados en el repositorio y regenerables por script. Tiene cuatro piezas:

- Datos: descarga por script de SPY (OHLC crudo, Adj Close y dividendos), del VIX y de la tasa DGS3MO, congelada en un snapshot con fecha y checksum. El build verifica los checksums, aplica el filtro de sanidad OHLC y construye el DataFrame compartido, incluida la varianza realizada Garman-Klass más overnight. En el snapshot actual no hubo ninguna sustitución por Parkinson ni ningún día con piso de varianza.
- Modelos: EWMA (media móvil con ponderación exponencial de los retornos al cuadrado), GARCH(1,1), HAR-RV (regresión de la varianza realizada sobre sus medias de 1, 5 y 22 días), gradient boosting (GBM en adelante, implementado con LightGBM), su variante con el VIX (índice de volatilidad implícita del S&P 500) y el benchmark sin modelo (media trailing de 21 días de la varianza realizada), todos detrás de la misma interfaz de tres métodos: re-estimación mensual, actualización diaria del estado y pronóstico de la vol diaria de *t+1*. Un loop de walk-forward común los corre con ventana expansiva y cachea los pronósticos con el commit y el snapshot que los produjo.
- Evaluación de pronósticos: QLIKE (la pérdida cuasi-verosimilitud, robusta a un proxy ruidoso de la varianza) y RMSE (raíz del error cuadrático medio) sobre varianzas, test de Diebold-Mariano de igualdad de precisión predictiva contra el GBM con errores estándar de Newey-West, y robustez al proxy alternativo (retornos al cuadrado).
- Backtester y evaluación de estrategias: motor propio vectorizado con la ecuación de timing fijada y testeada, banda de no-trade sobre el peso drifted, cap, costos y spread de fondeo, cada fricción con su toggle. Métricas brutas y netas, regresión de spanning con *t* de Newey-West, diferencia de Sharpe con bootstrap por bloques (Ledoit y Wolf, 2008), atribución de fricciones por capas y sensibilidades.

Los tests cubren lo mecánico: el estimador contra un cálculo a mano, la ausencia de look-ahead en las features y la alineación peso-retorno del backtester, incluido el tramo apalancado.

Junto con este documento se entrega el repositorio zippeado, donde el notebook *entregas/entrega3.ipynb* sigue estas mismas secciones y reproduce cada tabla que se cita: corre el backtester para todas las configuraciones y compara cada resultado con la versión cacheada. Se adjunta además el archivo *volatility-forecasting-entrega3-notebook.html*, con ese notebook ya corrido

2. Metodología

Hipótesis, como quedaron en la propuesta. H1, predictiva: el gradient boosting pronostica la volatilidad con menor error que EWMA, GARCH y HAR. H2, económica: la estrategia que

usa el mejor pronóstico mantiene la volatilidad realizada más cerca del objetivo y mejora el Sharpe frente a mantener SPY sin gestionar y frente a la misma estrategia con los otros modelos, antes de costos. H3, operativa: esas mejoras sobreviven a los costos de transacción, el rezago de ejecución y el turnover.

Período: enero de 2000 a junio de 2026. Ventana inicial de entrenamiento 2000 a 2009 y evaluación out-of-sample de 4147 días, del 4 de enero de 2010 al 30 de junio de 2026. Robustez con el corte de entrenamiento movido a 2008 y a 2012, mismo fin de muestra.

Frecuencia: diaria en todo el diseño. El target es la varianza diaria, el pronóstico es a un día y los pesos se recalculan a diario. GARCH, HAR y los dos GBM se re-estiman el último día de trading de cada mes (197 refits en la muestra); EWMA y trailing no tienen parámetros que estimar. Todos actualizan su estado a diario sin re-estimar. El GBM ajusta su grilla (learning rate y número de hojas, con el número de árboles por early stopping) en cada refit sobre un split cronológico 80/20 con embargo de 22 días.

Supuestos principales:

- Ningún cálculo en *t* usa información de *t+1* en adelante.
- El peso decidido con el cierre de *t* se ejecuta al cierre de *t+1* y gana el retorno de *t+1* a *t+2*. Este es el cambio respecto de la entrega 2, motivado por la devolución: el pronóstico necesita el cierre definitivo de *t*, así que una orden market-on-close en ese mismo cierre no es implementable. La convención anterior queda como toggle en la tabla de fricciones (ver sección 5).
- Vol objetivo de 10% anualizada, peso $w = \sigma_{obj} / \sigma_{pronosticada}$ acotado a [0, 1.5], remanente en cash a la tasa DGS3MO, apalancamiento fondeado a esa tasa más 50 bps.
- Banda de no-trade de 5 puntos porcentuales sobre el peso drifted; al romperla se opera hasta el objetivo. Costos de 2 bps one-way sobre el notional operado, con sensibilidad a 5 y 10 bps.
- Dos benchmarks: buy-and-hold de SPY y vol targeting sin modelo con la media trailing de 21 días, que separa el valor de pronosticar del valor del targeting en sí.

Construcción de posiciones: cada día *t*, con el pronóstico de vol de *t+1* se calcula el peso objetivo; si se desvía del peso vigente más que la banda, o si el drift dejó el peso por encima del cap, se opera hasta el objetivo al cierre de *t+1*. Entre operaciones el peso drifta con los retornos relativos de SPY y cash.

3. Resultados y análisis preliminares

3.1 Valor estadístico de los pronósticos

Tabla 1. Evaluación de pronósticos, out-of-sample 2010-2026, contra la varianza Garman-Klass más overnight. QLIKE y RMSE se calculan sobre varianzas diarias (RMSE por diez mil); en las dos, menor es mejor. DM es el estadístico de Diebold-Mariano de cada modelo contra el GBM base: positivo significa que el modelo pierde contra el GBM, y por encima de 2 en valor absoluto la diferencia es significativa al 5%.

Modelo	QLIKE	RMSE	DM vs GBM
Trailing 21d	0.524	3.83	7.25
EWMA	0.497	3.63	8.13
GARCH(1,1)	0.444	3.38	7.98
HAR-RV	0.419	3.35	4.48
GBM	0.379	3.03	
GBM + VIX	0.352	2.97	-4.74

El orden es limpio y las diferencias no son ruido: los cuatro Diebold-Mariano contra el GBM tienen p por debajo de 1e-5, y el GBM con VIX le gana al GBM base con la misma holgura. Bajo el proxy alternativo de retornos al cuadrado, que cae al piso de varianza en 58 días con retorno menor a un punto básico en valor absoluto, el orden de los cuatro modelos y del GBM con VIX es el mismo, trailing y EWMA intercambian los dos últimos lugares, y los estadísticos bajan (el más chico de los cuatro contra el GBM base, HAR, da 3.89). Con el corte de entrenamiento en 2008 y en 2012 el orden completo se mantiene.

3.2 Valor económico en la estrategia

Tabla 2. Estrategias, caso base (decisión diaria, vol objetivo 10%, apalancamiento máximo 1.5x, banda de no-trade de 5 puntos porcentuales, costo de 2 puntos básicos por operación, ejecución al cierre de *t+1*), 2010-2026. Sharpe: exceso de retorno sobre la tasa libre de riesgo dividido por su desvío, anualizado, neto de costos. Drawdown máximo: peor caída acumulada desde un máximo. Turnover: suma anual de los cambios de peso en valor absoluto, en veces el capital. Vol-of-vol: raíz del error cuadrático medio entre la vol anualizada rolling de 21 días de la estrategia y el objetivo de 10% (Hong, 2026); mide cuán bien la estrategia sostiene el riesgo que promete.

Estrategia	Sharpe neto	Drawdown máx.	Turnover anual	Vol realizada	Vol-of-vol
Buy-and-hold SPY	0.773	-33.7%	0.06x (compra inicial)	17.2%	0.1022
Trailing 21d	0.735	-16.0%	3.8x	10.9%	0.0346
EWMA	0.738	-15.5%	4.2x	10.6%	0.0332
GARCH(1,1)	0.744	-14.1%	6.8x	10.0%	0.0266
HAR-RV	0.760	-15.0%	15.2x	9.9%	0.0245
GBM	0.732	-15.7%	23.4x	10.1%	0.0235
GBM + VIX	0.732	-14.9%	23.1x	9.9%	0.0230

Dos lecturas conviven en la tabla. La primera es que el pronóstico sí se traslada al control de riesgo: el orden por vol-of-vol reproduce exactamente el de QLIKE, todas las estrategias llevan la vol realizada al target y el drawdown máximo baja de 34% a entre 14% y 16%. La segunda es que nada de eso aparece en el Sharpe: bruto de costos los seis modelos quedan entre 0.74 y 0.79 contra 0.77 del buy-and-hold, y neto entre 0.73 y 0.76, con el buy-and-hold apenas por encima de todos. La regresión de spanning (exceso de retorno de la estrategia sobre el exceso de SPY; el alfa es lo que la estrategia agrega sobre una exposición fija al índice) sobre retornos brutos da alfas anuales entre 0.7% y 1.1% con *t* entre 0.5 y 0.9, y ninguna de las 21 diferencias pareadas de Sharpe (test de Ledoit y Wolf, 2008, con bootstrap por bloques) es significativa (el p más bajo es 0.22). Sobre retornos netos los alfas bajan a entre 0.6% y 0.8% y sus p suben.

3.3 Dónde se pierde la ventaja

Los costos no explican la brecha. La atribución por capas muestra que pasar de la ejecución al cierre de *t* a la de *t+1* cuesta entre 0.03 y 0.06 de Sharpe (medido antes de cap, banda y costos), más para HAR, GBM y trailing que para EWMA y GARCH, y que los 2 bps le cuestan 0.047 al GBM, que opera 23 veces su capital por año contra 4 del EWMA. A 5 bps el GBM cae a 0.66 y a 10 bps a 0.55, mientras EWMA y trailing quedan en 0.72 a 0.73 a 5 bps y en 0.71 a 10 bps: el orden se invierte, pero ningún modelo alcanza al pasivo en ningún nivel de costos. Bajar la frecuencia de decisión tampoco recupera nada: Sharpe neto entre 0.71 y 0.73 con decisión semanal y entre 0.70 y 0.76 con mensual, con más castigo para HAR (0.760 diario, 0.695 mensual) que para EWMA (0.738 y 0.748); el GBM pierde poco en las dos.

Para dimensionar cuánto hay en juego se corrió el backtester con dos pronósticos de look-ahead deliberado, solo como diagnóstico y bajo la convención de ejecución al cierre de *t*, en la que se definen. Un oráculo que conoce la vol realizada del día que dimensiona da Sharpe neto 2.06 y uno que conoce solo la varianza media de los 21 días siguientes da 1.83, contra 0.81 del GBM con esa convención y 0.79 del pasivo sobre esa muestra común, algo más corta que la de la Tabla 2. Ordenando los días por la vol realizada del propio día, el retorno medio del quintil más volátil es -14 bps; ordenándolos por el pronóstico del GBM, +9 bps. La vol futura coincide con la caída, la vol ya conocida anticipa el rebote. Aleatorizando el signo de los retornos centrados (100 réplicas), lo que preserva la magnitud y el agrupamiento de la vol y deja los pronósticos intactos, la ventaja del oráculo de régimen sobre el GBM cae de 1.03 a 0.04, indistinguible de cero, y los seis modelos pasan a rendir entre 0.22 y 0.27 de Sharpe por encima del pasivo, contra entre -0.01 y 0.05 en los datos reales. La lectura es que el 96% de la distancia al techo es timing de retornos, información que ningún pronóstico construido con datos pasados mostró tener en esta muestra, y que en la muestra real el pago del vol targeting por control de riesgo se cancela contra la relación contemporánea negativa entre volatilidad y retorno.

Un dato más es consistente con esa lectura: el 68% de la ganancia de QLIKE del GBM con VIX sobre el GBM base está en el quintil más volátil, donde el peso σ_{obj} / $\sigma_{pronosticada}$ ya está

en su nivel más bajo y es casi plano. La precisión se gana justo donde el portafolio tiene menos capital expuesto.

4. Consistencia con la hipótesis

- H1 (el gradient boosting pronostica mejor): confirmada, con margen amplio y robusta a proxy y a corte de entrenamiento.
- H2 (la mejora estadística produce una cartera superior antes de costos): la parte descriptiva se sostiene en el control del target, cuyo orden reproduce el de QLIKE, y el drawdown, los peores días y la curtosis mejoran para todos aunque sin seguir ese orden, mientras la asimetría empeora (de -0.33 a entre -0.66 y -0.85); la inferencia formal no: ni el alfa de spanning ni la diferencia de Sharpe son distinguibles de cero, ni contra el pasivo ni entre modelos.
- H3 (después de costos): rechazada. Los costos reordenan a los modelos en contra de los que más operan y ninguno supera al pasivo.

El resultado es consistente con la posibilidad, planteada desde la propuesta, de que el ML no agregue valor económico, y con la evidencia previa. Cederburg et al. (2020) y Liu, Tang y Zhou (2019) muestran que el vol targeting de Moreira y Muir (2017) no le gana al pasivo out-of-sample en tiempo real; nuestro benchmark sin modelo es su estrategia en espíritu y da el mismo nulo en nuestra ventana. Hong (2026) encuentra que el gradient boosting pronostica mejor y que en la estrategia la ganancia es modesta, y Díaz, Hansen y Cabrera (2024) que las mejoras predictivas no se traducen en valor económico. Bollerslev, Hood, Huss y Pedersen (2018) encuentran que los modelos lentos ganan cuando entran los costos, lo mismo que muestra la sensibilidad de costos.

La brecha ya está documentada y el mecanismo ya está intuido: French, Schwert y Stambaugh (1987) para la relación negativa contemporánea entre volatilidad y retorno, Moreira y Muir (2017) para la debilidad del tradeoff riesgo-retorno. El aporte de este trabajo es de medición: juntar las dos cosas en un solo protocolo, con los mismos pronósticos y el mismo portafolio, separar cada fricción, y ponerle un número a cuánto de la distancia al techo es timing de retornos y cuánto es control de riesgo.

5. Problemas detectados

- Convención de ejecución. La regla de la entrega 2 decidía el peso con información hasta el cierre de *t* y lo ejecutaba en ese mismo cierre. La devolución señaló que no es implementable: todos los modelos necesitan el cierre definitivo de *t* (el retorno del día para EWMA y GARCH, el término de cierre del estimador para HAR y GBM), así que una orden market-on-close no puede usar un pronóstico calculado con el precio que esa orden fija. El caso base pasó a ejecutar al cierre de *t+1*. Medido sobre los mismos pronósticos en la capa de atribución, antes de cap, banda y costos, el cambio cuesta entre 0.03 y 0.06 de Sharpe, más a los modelos que reaccionan rápido (HAR, GBM y trailing) que a EWMA y GARCH, y con el rezago y neto de costos ningún

modelo supera al buy-and-hold. La convención anterior quedó como toggle de la tabla de fricciones.

- Corrección de sesgo lognormal en el GBM. HAR y GBM pronostican en log-varianza; al exponenciar se obtiene la mediana y no la media, y hay que sumar la mitad de la varianza de los residuos. Con los residuos in-sample el forecast del GBM quedaba sesgado a la baja: un boosting sobreajusta la muestra de entrenamiento y sus residuos subestiman la varianza real. La corrección pasó a estimarse sobre el 20% de validación del split de tuning, y el HAR usa el mismo split para que el procedimiento sea idéntico en los dos modelos en log.
- Turnover del GBM. Con la misma banda de 5 puntos porcentuales, los dos GBM operan 23 veces su capital por año contra 4 del EWMA y 15 del HAR, porque el pronóstico cambia más de un día al otro. La banda no lo doma: ensancharla de 5 a 10 puntos porcentuales solo lo baja de 23 a 20 veces por año; el costo de 2 bps le quita 0.047 de Sharpe al GBM y a 5 bps el orden entre modelos ya se invierte a favor de los lentos. Lo leemos como un problema de definición de regla, no de pronóstico: la regla traslada cada cambio del pronóstico al peso.
- Cap entre fechas de decisión. En las variantes de robustez con decisión semanal y mensual, el peso se fija en la fecha de decisión y entre decisiones solo drifta con los retornos relativos de SPY y cash, sin evaluar ni la banda ni el cap. Si SPY sube mientras la posición está apalancada, el peso mantenido puede pasar de 1.5x sin que la estrategia reaccione. Medido: en la variante semanal el máximo es 1.54x y ningún modelo está por encima del cap más del 0.9% de los días; en la mensual el EWMA llega a 1.59x y pasa el cap 65 días de 4146 operados. Se decidió no convertir el cap en un disparador diario, porque agregaría operaciones fuera de las fechas de decisión y volvería a mezclar frecuencia con control de riesgo, que es justo lo que esa robustez quiere separar. El cap queda como restricción que rige en la fecha de decisión, igual que en Moreira y Muir (2017) a frecuencia mensual, y la tabla lo aclara.

6. Próximos ajustes

- Configuración de la regla de sizing. Falta descartar que la brecha sea un artefacto de la configuración elegida: repetir el caso base con target de 15% y 20%, con cap de 2x, 3x y sin cap, y con la regla de escalado por varianza de Moreira y Muir (2017), midiendo en cada caso qué fracción de los días el peso queda pegado al cap. La hipótesis a contrastar es que la ventaja del GBM en QLIKE cae donde la regla actual no la usa.
- Regla de corte por volatilidad. Peso cero cuando el pronóstico supera un nivel fijado de antemano (30% anualizado, con sensibilidad a 20%). Es la única regla que usaría el pronóstico donde el GBM concentra su ventaja, y lo haría a través del signo del retorno, así que habría que etiquetarla como timing de retornos y no como control de riesgo. Sería también el test más directo de la convención de ejecución: si las salidas caen después de la caída y no sobre ella, la regla pierde.

- Utilidad realizada como escala económica de H1. Siguiendo Bollerslev, Hood, Huss y Pedersen (2018), la utilidad de un inversor media-varianza que dimensiona con cada pronóstico depende solo del cociente entre vol realizada y pronosticada; la idea es reportarla como fracción del techo de pronóstico perfecto, junto a QLIKE, para decir cuánto vale en riqueza la distancia entre modelos. Sería descriptiva, porque usa la raíz del proxy y no es robusta al ruido en el sentido de Patton (2011).
- Otros activos. Repetir el pipeline sin cambios sobre un panel de ETFs con OHLC desde principios de los 2000 (QQQ, IWM, EEM, GLD, TLT) y un portafolio combinado a riesgo igual, para saber si el nulo económico es propio de SPY o del vol targeting con pronóstico honesto. BTC aparte, con calendario de 365 días y sin overnight.

Bibliografía

- Bollerslev, T., Hood, B., Huss, J. y Pedersen, L. H. (2018). "Risk Everywhere: Modeling and Managing Volatility". *Review of Financial Studies*, 31(7), 2729–2773.
- Cederburg, S., O'Doherty, M. S., Wang, F. y Yan, X. (2020). "On the Performance of Volatility-Managed Portfolios". *Journal of Financial Economics*, 138(1), 95–117.
- Díaz, J. D., Hansen, E. y Cabrera, G. (2024). "Machine-learning stock market volatility: Predictability, drivers, and economic value". *International Review of Financial Analysis*, 94, 103286.
- French, K. R., Schwert, G. W. y Stambaugh, R. F. (1987). "Expected Stock Returns and Volatility". *Journal of Financial Economics*, 19(1), 3–29.
- Hong, X. (2026). "Forecasting and Managing Volatility with Machine Learning". *SSRN Working Paper* N.º 6277518.
- Ledoit, O. y Wolf, M. (2008). "Robust Performance Hypothesis Testing with the Sharpe Ratio". *Journal of Empirical Finance*, 15(5), 850–859.
- Liu, F., Tang, X. y Zhou, G. (2019). "Volatility-Managed Portfolio: Does It Really Work?". *Journal of Portfolio Management*, 46(1), 38–51.
- Moreira, A. y Muir, T. (2017). "Volatility-Managed Portfolios". *Journal of Finance*, 72(4), 1611–1644.
- Patton, A. J. (2011). "Volatility Forecast Comparison Using Imperfect Volatility Proxies". *Journal of Econometrics*, 160(1), 246–256.