Finanzas Computacionales

UCEMA - 2026



Entrega 4: Robustez, sensibilidad y evaluación crítica del backtest

Pronóstico de volatilidad del S&P 500 aplicado a una estrategia de volatility targeting

Alumnos: Andrés Otero y Ezequiel Telias

La entrega 3 dejó un resultado con dos caras. El gradient boosting pronostica la volatilidad de SPY claramente mejor que EWMA, GARCH y HAR, y ese mejor pronóstico se traduce en un mejor control del riesgo de la cartera, pero no en un mejor Sharpe. Esta entrega pone a prueba ese resultado: busca qué fecha, qué parámetro o qué supuesto de ejecución lo podría romper, y evalúa qué tan confiable es el backtest que lo produce.

1. Qué cambió a partir de la devolución

La devolución de la entrega 3 señaló tres cosas que cambian cómo se lee el resto del documento.

El desfase entre pronóstico y retorno ahora se mide. La devolución marcó que el horizonte pronosticado y el retorno capturado no coinciden: al cierre del lunes se pronostica la volatilidad del martes, pero la orden se ejecuta al cierre del martes y la posición gana el retorno del miércoles. Atacamos el problema de tres formas. Primero, comparamos con la ejecución en el mismo cierre, donde el horizonte sí coincide. Segundo, medimos cuánta precisión pierde el pronóstico al aplicarse un día tarde. Tercero, construimos un pronóstico a dos días, que apunta directamente al día del retorno. El desfase tiene un costo en todos los modelos, pero ninguna de las tres alternativas cambia la conclusión. La sección 5 tiene el detalle.

La explicación del apalancamiento estaba al revés. En la entrega 3 dijimos que, con la cartera apalancada, una suba de SPY podía llevar el peso por encima del cap entre rebalanceos. Es al contrario. Con 100 de patrimonio y peso 1.5 la cartera tiene 150 en SPY y 50 de deuda. Si SPY sube 10%, la posición pasa a 165, el patrimonio a 115 y el peso baja a 1.43. Si SPY cae 10%, la posición pasa a 135, el patrimonio a 85 y el peso sube a 1.59. Los excesos sobre el cap que medimos en las variantes semanal y mensual siguen siendo correctos, pero ocurren después de caídas, no de subas.

La conclusión se acota a lo que la evidencia permite decir. No se encontró evidencia de una mejora económica bajo las reglas, el activo y la muestra evaluados. Eso no demuestra que la mejora sea imposible, y la sección 7 discute dónde podría estar.

2. El resultado bajo prueba

Dos medidas ordenan la tabla. La primera evalúa el pronóstico. QLIKE compara, para cada día, la varianza pronosticada h con la varianza realizada σ² medida con el estimador Garman-Klass más overnight, y promedia $\sigma^2/h - \ln(\sigma^2/h) - 1$ sobre la muestra. Vale cero si el pronóstico es exacto y crece con el error. Castiga más subestimar la varianza que sobreestimarla, que es el error más caro en una estrategia que se apalanca cuando el pronóstico es bajo. Además, el ranking de modelos que produce sigue siendo correcto aunque la varianza realizada se mida con ruido, siempre que el estimador sea insesgado (Patton, 2011). Por eso es la métrica principal de precisión. Menor es mejor, y las diferencias entre modelos se testean con el test de Diebold y Mariano (1995).

La segunda evalúa la estrategia. Para medir el control del riesgo usamos el vol-of-vol de Hong (2026). Cada día se calcula la volatilidad anualizada de la estrategia en los últimos 21 días y se la compara con el objetivo de 10%. El vol-of-vol es la raíz del promedio de esas diferencias al cuadrado. Un valor de 0.023 significa que la volatilidad de la estrategia se aparta del objetivo, típicamente, unos 2.3 puntos porcentuales. A pesar del nombre, no es la dispersión de la volatilidad alrededor de su propia media: penaliza tanto que la volatilidad oscile como que se quede lejos del objetivo. Una estrategia estable en 13% tiene un vol-of-vol alto aunque su volatilidad no se mueva. Es la medida directa de lo que el vol targeting promete, sostener un nivel de riesgo fijo.

Tabla 1. Caso base: decisión diaria, vol objetivo de 10% anualizada, cap de 1.5x, banda de no-trade de 5 puntos porcentuales, costo de 2 bps por operación y ejecución al cierre siguiente a la decisión. Los modelos están ordenados por QLIKE, de peor a mejor.

Estrategia	QLIKE	Sharpe neto	Vol realizada	Vol-of-vol	Drawdown máx.	Turnover anual
Pasivo (buy-and-hold SPY)		0.773	17.2%	0.102	−33.7%	0.06x
Trailing 21 días	0.524	0.735	10.9%	0.035	−16.0%	3.8x
EWMA	0.497	0.738	10.6%	0.033	−15.5%	4.2x
GARCH(1,1)	0.444	0.744	10.0%	0.027	−14.1%	6.8x
HAR-RV	0.419	0.760	9.9%	0.025	−15.0%	15.2x
GBM	0.379	0.732	10.1%	0.023	−15.7%	23.4x
GBM + VIX	0.352	0.732	9.9%	0.023	−14.9%	23.1x

La tabla resume la tesis. Leída por columnas, el control del riesgo sigue a la precisión del pronóstico: cada mejora en QLIKE, todas significativas en el test de Diebold-Mariano, se refleja en un vol-of-vol más bajo, en el mismo orden, todas las estrategias llevan la volatilidad al objetivo y todas reducen el drawdown a menos de la mitad del pasivo. El Sharpe, en cambio, no sigue a nadie: los seis modelos quedan en una banda angosta por

debajo del pasivo, y ninguna diferencia, entre modelos o contra el pasivo, es estadísticamente significativa. La pregunta de esta entrega es si alguna de esas dos lecturas depende de cómo se armó el experimento.

3. ¿Depende del momento?

3.1 Corte de entrenamiento

Se repitió todo con el primer año out-of-sample en 2009 y en 2013, en lugar de 2010.

Tabla 2. Por corte de entrenamiento. El p es el más bajo de las seis estrategias contra el pasivo del mismo corte.

		EWMA	GARCH	HAR	GBM	GBM + VIX	Trailing	Pasivo	p mínimo
OOS desde 2009	Sharpe	0.769	0.766	0.784	0.756	0.758	0.768	0.783	0.82
	Vol-of-vol	0.033	0.026	0.024	0.023	0.023	0.034	0.107	
OOS desde 2010 (base)	Sharpe	0.738	0.744	0.760	0.732	0.732	0.735	0.773	0.72
	Vol-of-vol	0.033	0.027	0.025	0.023	0.023	0.035	0.102	
OOS desde 2013	Sharpe	0.751	0.746	0.792	0.777	0.782	0.765	0.801	0.66
	Vol-of-vol	0.034	0.027	0.025	0.024	0.023	0.035	0.101	

Las dos caras del resultado se comportan distinto. El control del riesgo es estable: el orden por vol-of-vol es el de QLIKE en los tres cortes, y el ranking de precisión del pronóstico tampoco se mueve, con todas las diferencias contra el GBM significativas. El orden por Sharpe, en cambio, se reacomoda de un corte a otro; el GBM es el peor en dos cortes y queda en el medio en el tercero. Es lo esperable de diferencias que están dentro del ruido.

3.2 Sub-períodos

Tabla 3. El caso base dividido en dos mitades y sin 2020, el año del pico de volatilidad más grande de la muestra.

		EWMA	GARCH	HAR	GBM	GBM + VIX	Trailing	Pasivo	p mínimo
2010-2017	Sharpe	0.908	0.897	0.844	0.815	0.838	0.868	0.931	0.42
	Vol-of-vol	0.030	0.026	0.024	0.024	0.023	0.032	0.075	
2018-2026	Sharpe	0.585	0.610	0.684	0.660	0.638	0.615	0.671	0.59
	Vol-of-vol	0.036	0.028	0.025	0.023	0.024	0.037	0.123	
Sin 2020	Sharpe	0.757	0.742	0.754	0.724	0.725	0.751	0.818	0.26
	Vol-of-vol	0.032	0.026	0.024	0.022	0.022	0.033	0.081	

Tres lecturas. Primero, el nivel de todos los Sharpe, pasivo incluido, cae de una mitad a la

otra: es la muestra la que cambia, no la estrategia. Segundo, el orden por Sharpe se invierte entre mitades (en la primera ganan los modelos lentos, en la segunda el HAR y los GBM), mientras el orden por control de riesgo se mantiene. Tercero, sin 2020 la brecha contra el pasivo se ensancha. Es el año en que el vol targeting más protegió, y aun así es el que más lo acerca al pasivo, porque la estrategia salió de la caída desapalancada y se perdió parte del rebote. Ese es el mismo mecanismo que se midió en la entrega 3: la volatilidad que un pronóstico honesto puede ver llega después de la caída.

3.3 Día de la decisión semanal

La variante de decisión semanal decidía siempre el viernes. Se repitió anclando la decisión en cada día de la semana, con todo lo demás igual.

Tabla 4. Decisión semanal según el día ancla. El pasivo es el mismo en las cinco filas.

		EWMA	GARCH	HAR	GBM	GBM + VIX	Trailing	p mínimo
Lunes	Sharpe	0.723	0.743	0.763	0.752	0.758	0.740	0.64
	Vol-of-vol	0.038	0.031	0.029	0.029	0.027	0.038	
Martes	Sharpe	0.746	0.769	0.799	0.803	0.788	0.764	0.78
	Vol-of-vol	0.039	0.033	0.030	0.029	0.028	0.039	
Miércoles	Sharpe	0.719	0.711	0.747	0.680	0.661	0.735	0.23
	Vol-of-vol	0.041	0.035	0.032	0.032	0.031	0.040	
Jueves	Sharpe	0.726	0.744	0.766	0.793	0.770	0.740	0.61
	Vol-of-vol	0.038	0.032	0.029	0.028	0.027	0.039	
Viernes	Sharpe	0.718	0.727	0.706	0.719	0.710	0.712	0.50
	Vol-of-vol	0.038	0.032	0.031	0.030	0.030	0.040	

Este es el resultado más ilustrativo de la entrega, y su lectura es que el reordenamiento del Sharpe es ruido. Nada en la estrategia cambia entre filas: los mismos pronósticos, la misma regla, las mismas fricciones; solo se corre el día en que se toma la decisión. No hay ninguna razón económica para que los dos GBM sean los peores modelos los miércoles y el GBM el mejor los martes, y sin embargo eso es lo que muestra la tabla. Que una elección arbitraria mueva el Sharpe de un modelo más de lo que lo separa de cualquier otro en el caso base dice que esas diferencias están dentro de la variación que produce el azar de qué días le tocan a cada peso. Lo confirman los tests de diferencia de Sharpe. Ninguna estrategia le gana al pasivo de forma estadísticamente significativa en ningún día. Entre los cinco días se hicieron 105 comparaciones de a pares, y solo una resulta significativa al 5%: HAR contra GBM con VIX el miércoles. Con un nivel de 5%, una de cada veinte comparaciones sale significativa por puro azar aunque no haya ninguna diferencia real, así que encontrar una

sola entre 105 es menos de lo que el azar produciría por sí solo.

El control del riesgo, en cambio, no se reordena. Los mismos modelos quedan arriba y abajo en vol-of-vol los cinco días. El día de la semana cambia qué retornos le tocan a cada peso, no qué tan bien ese peso controla la volatilidad. La conclusión vale para todo el documento: cuando un ranking de Sharpe entre modelos cambia con un detalle de implementación que no debería importar, ese ranking no es evidencia de nada; un ranking que se mantiene, como el de control de riesgo, sí lo es.

4. ¿Depende de cómo se arma la regla?

Cada variante cambia un parámetro del caso base y deja el resto igual.

- **Frecuencia de decisión.** Con decisión semanal o mensual el turnover del GBM cae a un tercio y a un décimo, y el Sharpe no mejora para ningún modelo. La brecha con el pasivo no es, entonces, un problema de operar demasiado. Entre decisiones la banda y el cap no se evalúan y el peso drifta; como se explicó en la sección 1, los excesos sobre el cap ocurren cuando SPY cae.
- **Banda de no-trade.** Entre 0 y 10 puntos porcentuales controla el turnover pero no cambia ni el orden entre modelos ni la distancia al pasivo.
- **Vol objetivo y cap.** Con 10% de objetivo el cap casi nunca se toca, y subirlo o quitarlo no cambia nada. Con 15% y 20% el cap empieza a mandar, la dispersión entre modelos crece y el orden pasa a ser el inverso del de QLIKE: ganan GARCH y EWMA, los modelos lentos. Nadie supera al pasivo en ningún objetivo.
- **Regla de sizing.** Escalar por varianza en lugar de por volatilidad (la regla de Moreira y Muir, 2017) empeora a todos: mueve el peso el doble ante cada cambio del pronóstico y multiplica el turnover. Apagar la posición cuando el pronóstico supera un umbral, la única regla que usa el pronóstico justo donde el GBM es más preciso, también pierde, porque los días que marca como peligrosos rinden en promedio más que los demás: llegan después de la caída.
- **Proxy de volatilidad.** Evaluando contra los retornos al cuadrado en lugar del estimador Garman-Klass más overnight, el ranking de precisión es el mismo.

Ninguna de las variantes probadas, más agresivas o más conservadoras, convierte la precisión del pronóstico en un Sharpe mayor.

5. ¿Depende de cómo y cuándo se opera?

5.1 El desfase entre pronóstico y retorno

Este es el punto que señaló la devolución, y resultó ser el supuesto más importante del backtest.

Tabla 5. Sharpe neto según la convención de ejecución. Las tres primeras filas no tienen cap, banda ni costos y difieren solo en cuándo se aplica el peso. La cuarta usa un pronóstico construido para el día del retorno. Las últimas agregan las fricciones de a una; la última fila es el caso base.

Convención	EWMA	GARCH	HAR	GBM	GBM + VIX	Trailing
Peso aplicado al mismo día que pronostica (look-ahead, solo diagnóstico)	1.072	1.315	1.325	2.588	2.771	0.979
Orden al mismo cierre de la decisión	0.782	0.806	0.850	0.824	0.825	0.811
Orden al cierre siguiente (implementable)	0.749	0.771	0.796	0.773	0.784	0.762
Ídem, con pronóstico a dos días	0.749	0.775	0.799	0.798	0.804	0.762
+ cap	0.752	0.772	0.794	0.772	0.778	0.756
+ banda	0.746	0.758	0.791	0.779	0.779	0.742
+ costos (caso base)	0.738	0.744	0.760	0.732	0.732	0.735

La tabla se lee de arriba hacia abajo como una escalera de información. La primera fila no es una estrategia posible: aplica el peso al día cuya volatilidad ya se conoce. Sirve para medir cuánto vale esa información, y para los modelos que mejor pronostican vale casi dos puntos de Sharpe. Esto confirma lo que mostró el oráculo de la entrega 3: lo valioso es la volatilidad contemporánea, porque coincide con la caída.

La segunda fila es la convención que asume la literatura, operar en el mismo cierre con el que se calcula el pronóstico. No es implementable con datos diarios, porque el pronóstico necesita ese cierre definitivo; la defensa habitual es operar unos minutos antes, y una medición con barras de cinco minutos muestra que esa aproximación funciona casi siempre pero falla justo en los cierres más movidos. Corrida con las mismas fricciones que el caso base, esta convención deja a varios modelos levemente por encima del pasivo, ninguno de forma significativa.

Entre la segunda y la tercera fila está el costo del día de retraso. Es real, del orden de la distancia entre modelos, y no cambia la conclusión. Medido como pronóstico, aplicar el pronóstico un día tarde sube el QLIKE alrededor de 10% en EWMA, GARCH y HAR y de 16% en los dos GBM, sin cambiar el orden entre modelos. El pronóstico a dos días,

construido para el día del retorno, recupera la mitad de ese costo en los GBM y casi nada en el resto; evaluado como pronóstico, reentrenar para el día correcto recupera poco de la precisión perdida. Lo que se pierde al llegar un día tarde no es un defecto del modelo, es la información que deja de estar disponible.

5.2 Ejecución dentro del día

Una alternativa es comparar la ejecución al cierre con la apertura o con un precio promedio del día. Se prototipó la ejecución en la apertura siguiente a la decisión: el peso viejo gana el tramo overnight y el nuevo el resto del día. Recupera casi todo el costo del retraso en los modelos lentos y no en los GBM. No se incorporó como variante versionada. Esperamos que un precio de ejecución dentro del día, sea la apertura, el VWAP o el promedio de open, high, low y close, dé resultados en la zona entre las dos convenciones de la Tabla 5, porque combina el peso de la víspera y el nuevo en proporciones intermedias; ninguna de esas dos convenciones cambia la inferencia. No es una cota exacta: el resultado depende de cómo se reparte el retorno del día entre el tramo overnight y el intradiario.

5.3 Latencia

La estrategia es diaria, así que la latencia que importa se mide en días, no en milisegundos. La vida útil de la señal la da la persistencia de la volatilidad, que es alta: por eso un día de retraso cuesta poco en precisión, aunque en Sharpe cuesta tanto como la distancia entre modelos. El salto grande de la Tabla 5 no está entre ejecutar hoy o mañana sino entre conocer o no la volatilidad del día que se dimensiona, y ese salto ningún retraso implementable lo puede cerrar.

5.4 Costos, liquidez y escalabilidad

Tabla 6. Sharpe neto por costo de transacción por operación. El pasivo paga solo la compra inicial.

Costo	EWMA	GARCH	HAR	GBM	GBM + VIX	Trailing	Pasivo
2 bps (base)	0.738	0.744	0.760	0.732	0.732	0.735	0.773
5 bps	0.727	0.724	0.714	0.662	0.663	0.724	0.773
10 bps	0.707	0.690	0.635	0.546	0.546	0.707	0.773

Los costos no explican la brecha, porque ya con 2 bps nadie alcanza al pasivo, pero sí reordenan a los modelos: a partir de 5 bps los que mejor pronostican son los que peor rinden, porque son los que más operan.

SPY es el activo más líquido del mercado, con un spread de un centavo sobre un precio de cientos de dólares. Los 2 bps del caso base cubren ese spread y un slippage razonable; 5 y

10 bps funcionan como estrés para días de pánico o para tamaños que empiecen a mover el precio. No se modeló impacto de mercado en función del tamaño, porque con este nivel de liquidez el costo lineal es la aproximación habitual.

En cuanto a escalabilidad, el volumen de SPY no es una restricción práctica. Su volumen diario promedio en dólares va de unos 24 mil millones en 2010 a unos 50 mil millones en 2026. Aun en la variante que más opera, el GBM, con un capital de mil millones de dólares la operación de un día típico representa menos del 0.5% del volumen del día. Para tamaños mucho mayores, el límite lo pondría el volumen de la subasta de cierre, que es una fracción del volumen total, y de nuevo los modelos que más operan serían los primeros en sentirlo.

6. Qué tan confiable es el backtest

Lo que lo hace confiable: no hay look-ahead en el caso base y la alineación entre peso y retorno está testeada; los datos son un snapshot congelado; la métrica principal de precisión es robusta al ruido del proxy de volatilidad (Patton, 2011); los costos y el fondeo del apalancamiento se cobran; y el tuning del GBM ocurre dentro del walk-forward. Sobre todo, el resultado central sobrevive a cada prueba de las secciones 3 a 5.

Los riesgos, en orden de importancia:

- **Un activo y una muestra.** Todo es SPY entre 2010 y 2026, un período dominado por un mercado alcista con episodios de volatilidad cortos. Estudios con muestras largas que incluyen 2008 encuentran mejoras de Sharpe para el vol targeting en acciones, sobre todo por la cola izquierda (Harvey et al., 2018). Acá se reproduce la reducción de la cola, pero no el Sharpe.
- **Pruebas diseñadas después de ver los resultados.** Los parámetros del caso base se fijaron antes de correr. Las variantes de esta entrega se diseñaron después de ver el caso base y se presentan como diagnósticos, no como búsqueda de una configuración ganadora; ninguna gana. El riesgo inverso es haber dejado de buscar demasiado pronto una regla que sí funcione.
- **Multiplicidad.** Con muchas estrategias, pares y configuraciones, algún p-valor bajo aparece por azar. Ningún modelo supera al pasivo de forma significativa en ninguna configuración, y el único p cercano a 0.05 contra el pasivo es en contra del GBM, con costos altos.
- **La convención de ejecución decide el signo.** Con la orden al mismo cierre algunos modelos quedan por encima del pasivo; con la implementable, ninguno. El backtest no elige la convención favorable, la cuantifica, pero es el supuesto al que el resultado es más sensible.
- **Fricciones simplificadas.** Costos constantes en dieciséis años, fondeo sin llamadas de margen, cash a la tasa de la letra a tres meses y sin impuestos. Las que importan,

costos e impuestos, favorecen a los modelos que más operan, así que corregirlas no ayudaría a los GBM.
- **Una semilla y un proxy ruidoso.** El GBM corre con una semilla fija y el proxy de volatilidad incluye un término overnight ruidoso. Ninguna de las dos cosas amenaza el ranking de precisión, que es muy holgado. El ranking económico ya está dentro del ruido.

7. Conclusiones del research

Como estrategia de retorno, el vol targeting con pronóstico de machine learning sobre SPY resultó débil en este diseño: en ninguna configuración probada supera al pasivo de forma significativa, y con costos realistas los modelos que mejor pronostican rinden peor. Como herramienta de control de riesgo es sólida: lleva la volatilidad al objetivo, reduce el drawdown a menos de la mitad, y mejora en el mismo orden en que mejora el pronóstico, de forma estable frente a cada cambio de fecha, parámetro o convención.

El resultado es sensible a dos supuestos: el momento de ejecución y el nivel de costos. Es robusto al resto. La sensibilidad al día de la semana, del mismo tamaño que la diferencia entre modelos, confirma que esa diferencia de Sharpe es ruido.

Bajo las reglas, el activo y la muestra evaluados no se encontró evidencia de que la mejora predictiva produzca una mejora económica, lo que no demuestra que sea imposible. El mecanismo que explica la brecha también indica dónde buscar: la precisión del GBM se concentra en los días de volatilidad alta, donde la regla tiene menos capital expuesto y donde el retorno contemporáneo es negativo. Un pronóstico honesto ve la volatilidad alta después de la caída, desapalanca tarde y se pierde el rebote. Tres líneas de investigación se desprenden de eso:

- **Operar la varianza directamente,** con una posición sintética de varianza sobre SPY contra el VIX. Ahí el error de pronóstico es el pago, y la precisión entra al resultado sin pasar por el signo del retorno.
- **Otros activos,** donde la relación entre volatilidad y retorno sea distinta a la del índice de acciones y el mismo pronóstico pueda pagar.
- **Reglas que no reduzcan la exposición justo cuando el pronóstico es más preciso,** diseñadas por escrito antes de correrlas, porque todas las tablas out-of-sample de esta muestra ya fueron vistas.

Bibliografía

- Diebold, F. X. y Mariano, R. S. (1995). "Comparing Predictive Accuracy". *Journal of Business & Economic Statistics*, 13(3), 253–263.
- Harvey, C. R., Hoyle, E., Korgaonkar, R., Rattray, S., Sargaison, M. y Van Hemert, O. (2018). "The Impact of Volatility Targeting". *Journal of Portfolio Management*, 45(1), 14–33.
- Hong, X. (2026). "Forecasting and Managing Volatility with Machine Learning". *SSRN Working Paper* N.º 6277518.
- Ledoit, O. y Wolf, M. (2008). "Robust Performance Hypothesis Testing with the Sharpe Ratio". *Journal of Empirical Finance*, 15(5), 850–859.
- Moreira, A. y Muir, T. (2017). "Volatility-Managed Portfolios". *Journal of Finance*, 72(4), 1611–1644.
- Patton, A. J. (2011). "Volatility Forecast Comparison Using Imperfect Volatility Proxies". *Journal of Econometrics*, 160(1), 246–256.