Finanzas Computacionales

UCEMA - 2026



Propuesta preliminar de tesina

Pronóstico de volatilidad del S&P 500 aplicado a una estrategia de volatility targeting

Alumnos: Andrés Otero y Ezequiel Telias

1. Idea inicial

La volatilidad del mercado accionario no es constante, pero tampoco se mueve de forma aleatoria: los períodos agitados tienden a durar, y los tranquilos también. Esa persistencia hace que la volatilidad sea mucho más pronosticable que los retornos, y esa es la observación de la que parte este trabajo.

La idea es usar esos pronósticos para manejar el riesgo de una cartera simple. Cada día se pronostica la volatilidad del S&P 500 para el período siguiente y se ajusta la posición en SPY: si el riesgo esperado sube, se achica la exposición; si baja, se agranda, con un tope para no apalancarse de más. El capital que no está en SPY queda en un activo libre de riesgo. La exposición de cada día se calcula dividiendo la volatilidad objetivo por la volatilidad pronosticada. Esta es la regla que se usa habitualmente en las estrategias de volatility targeting.

El pronóstico se puede generar de muchas maneras, y ahí está la pregunta del trabajo. Vamos a comparar tres modelos econométricos, EWMA, GARCH y HAR, contra un modelo de machine learning, gradient boosting. Pero no nos interesa solamente cuál pronostica mejor: nos interesa si un mejor pronóstico produce una mejor estrategia una vez que se incluyen costos y restricciones realistas. Como veremos en la evidencia previa, esas dos cosas no son lo mismo.

2. Motivación

Una cartera que mantiene siempre la misma posición en SPY no mantiene siempre el mismo riesgo: cuando la volatilidad del mercado se dispara, el riesgo de la cartera se dispara con ella. En la práctica, un inversor pasivo termina concentrando la mayor parte de su riesgo en las crisis, que es exactamente cuando menos lo quiere.

El volatility targeting invierte ese esquema: fija el nivel de riesgo y deja que la exposición varíe. Aunque no mejorará el retorno promedio, tiene beneficios potenciales por sí mismo: una volatilidad realizada más estable, drawdowns menores y menos retornos extremos.

El punto es que toda la estrategia depende de la calidad del pronóstico. Si el modelo subestima la volatilidad, la cartera queda sobreexpuesta cuando llega el golpe; si la sobreestima, se queda fuera del mercado sin necesidad. Por eso tiene sentido comparar modelos. Los econométricos clásicos son simples, rápidos y transparentes, pero traen la relación ya escrita: la volatilidad de mañana es una función fija de la de hoy, y el modelo solo ajusta los coeficientes. El machine learning aprende la relación directamente de los datos, así que puede capturar patrones que esa fórmula no expresa, como que la volatilidad reacciona más a las caídas que a las subas. El costo es que también puede aprender patrones que no

existen: tiene más hiperparámetros y más maneras de sobreajustar. El objetivo de este trabajo es llevar eso a la práctica y ver si podemos aprovechar esa posibilidad.

3. Hipótesis económica y financiera

La lógica de la estrategia se apoya en dos supuestos económicos. El primero es la persistencia de la volatilidad, el volatility clustering: la información reciente sirve para pronosticar la varianza futura. Este supuesto es el que formaliza los modelos de la familia ARCH que vamos a usar como referencia. EWMA pronostica la varianza como un promedio del pasado con pesos que decaen exponencialmente, GARCH agrega una varianza de largo plazo y separa la reacción a la información nueva de la persistencia y HAR pronostica con una regresión sobre la volatilidad de ayer, la de la última semana y la del último mes, capturando la persistencia a distintas escalas de tiempo. Gradient boosting no impone ninguna forma: construye el pronóstico combinando muchos árboles de decisión sobre un conjunto de predictores, y en principio puede aprender patrones que los otros tres no representan.

El segundo supuesto es que el mercado no compensa proporcionalmente los aumentos de varianza. Si el premio por riesgo subiera uno a uno con la volatilidad, reducir exposición en los momentos de riesgo alto no serviría de nada. La evidencia empírica sugiere que en horizontes cortos esa compensación es débil o inexistente: como muestran Moreira y Muir (2017), la volatilidad se mueve mucho más que el premio por riesgo, así que la relación retorno-riesgo empeora justo en los períodos agitados. Bajo ese supuesto, recortar exposición cuando el riesgo pronosticado sube puede mejorar el desempeño ajustado por riesgo.

De ahí salen las tres hipótesis a contrastar:

- **H1 (predictiva):** gradient boosting pronostica la volatilidad con menor error que EWMA, GARCH y HAR.
- **H2 (económica):** la estrategia que usa el mejor pronóstico mantiene la volatilidad realizada más cerca del objetivo y mejora el Sharpe frente a mantener SPY sin gestionar y frente a la misma estrategia con los otros modelos.
- **H3 (operativa):** esas mejoras sobreviven a los costos de transacción, el rezago de ejecución, el turnover y la restricción de usar únicamente información disponible en cada fecha.

Cualquiera de las tres puede rechazarse, y eso también sería un resultado válido. No partimos de la idea de que el gradient boosting o el volatility targeting tengan que ganar.

4. Research inicial

Revisamos literatura académica y research de practitioners para fundamentar tres decisiones de diseño: contra qué comparar, cómo definir la estrategia y cómo evaluar los pronósticos.

Los modelos de referencia salen de la literatura econométrica clásica: Engle (1982) introdujo los modelos ARCH, Bollerslev (1986) los generalizó con GARCH, y el RiskMetrics Technical Document de J.P. Morgan (1996) instaló al EWMA como estándar de la industria para medir riesgo. Como benchmarks elegimos EWMA, GARCH(1,1) y HAR. Los dos primeros son el estándar instalado en la industria para medir riesgo; HAR (Corsi, 2009) es más reciente y domina la literatura académica de pronóstico de volatilidad. Si el modelo de machine learning no le gana a ninguno de los tres, no hay motivo para asumir su complejidad.
Para la estrategia nos basamos en Moreira y Muir (2017), el punto de partida de la literatura moderna sobre este tipo de estrategias, que además define cómo evaluarlas económicamente: contra la versión sin gestionar, con alfa, Sharpe y ganancia de utilidad como métricas. Como referencia de implementación tomamos Harvey et al. (2018), un trabajo de practitioners de Man Group que aplica el targeting sobre un solo activo riesgoso con el resto en tasa y un tope de apalancamiento, que es la misma estructura de cartera que proponemos.

Para la evaluación de pronósticos, el punto técnico clave es que la volatilidad verdadera no se observa: hay que aproximarla con un proxy. Como proxy diario usamos el estimador de Garman y Klass (1980), que aprovecha la apertura, el máximo, el mínimo y el cierre de cada día y es sustancialmente más preciso que el retorno al cuadrado, sin requerir datos intradiarios. Ese proxy cumple una doble función: es el insumo del modelo HAR y el objetivo contra el que se evalúan los cuatro modelos. Aun así el proxy es imperfecto, y Patton (2011) mostró que en ese caso varias funciones de pérdida usuales pueden ordenar mal los modelos. Por eso la métrica principal va a ser QLIKE, que pertenece a la clase de pérdidas robustas que Patton caracteriza, con RMSE como métrica secundaria. La significancia de las diferencias entre modelos se evalúa con el test de Diebold-Mariano.

5. Evidencia previa

La pregunta del trabajo toca dos literaturas que corrieron bastante separadas: la de pronóstico de volatilidad y la de estrategias basadas en volatilidad. Repasamos qué se sabe en cada una y en su cruce.

Pronóstico. Durante años la conclusión fue que era muy difícil ganarle a un GARCH(1,1): eso encontraron Hansen y Lunde (2005) al comparar 330 especificaciones de la familia ARCH, aunque en acciones los modelos que

incorporan el efecto apalancamiento sí mostraban ventaja. Corsi (2009) propuso después el modelo HAR, hoy el benchmark habitual cuando se trabaja con volatilidad realizada. Los trabajos recientes con machine learning muestran mejoras, pero con matices que nos importan. Christensen, Siggaard y Veliyev (2023) encuentran que los métodos de ML le ganan a la familia HAR sobre las acciones del Dow Jones incluso con poco tuning, con ganancias más marcadas en horizontes largos. Díaz, Hansen y Cabrera (2024), trabajando sobre el S&P 500 con un conjunto amplio de predictores, encuentran que el ML supera al HAR solo en el horizonte corto, que los métodos más competitivos son la regularización y las redes neuronales (no los árboles) y, lo más importante para nosotros, que las ganancias predictivas no se traducen en ganancias económicas sustanciales. Y hay resultados directamente escépticos: Kilic (2025), en un paper de la Reserva Federal, compara una batería de métodos de ML contra modelos econométricos sobre la volatilidad realizada del S&P 500 y encuentra que los modelos HAR con cambio de régimen les ganan de manera consistente. El antecedente más parecido a nuestra primera parte es Lolic (2025), que compara random forest y gradient boosting contra EWMA y GARCH sobre el S&P 500 con datos diarios y validación purgada al estilo López de Prado: los árboles ganan fuera de muestra, y mejoran un poco más al agregar el VIX como predictor.

Estrategia. La evidencia sobre volatility targeting está dividida. A favor: Moreira y Muir (2017) encuentran alfas positivas y mejoras de Sharpe escalando factores accionarios de forma inversa a la varianza del mes anterior, con muestras largas; Harvey et al. (2018) analizan más de 60 activos y encuentran que el beneficio se concentra en renta variable y crédito, con la reducción de drawdowns como efecto más robusto. En contra: Cederburg, O'Doherty, Wang y Yan (2020) evalúan 103 estrategias y muestran que las alfas de las regresiones no equivalen a carteras que un inversor pudiera haber operado en tiempo real: implementadas de forma realista, las versiones gestionadas suelen rendir menos que las simples. Bongaerts, Kang y van Dijk (2020) agregan que parte de la evidencia favorable depende de calibraciones hechas con datos posteriores, y que el targeting ingenuo puede terminar tomando más riesgo del que declara. De esta discusión sacamos una regla de diseño: todo lo que reportemos tiene que poder construirse con la información disponible en su fecha.

El cruce. Los trabajos que conectan pronósticos de ML con estrategias de targeting son muy pocos. El más directo es Hong (2026), un working paper reciente de un investigador de Dimensional Fund Advisors, que primero compara modelos de ML contra benchmarks HAR sobre el S&P 500 y después evalúa si estos pronósticos mejoran estrategias de target volatility. Encuentra que los árboles con gradient boosting sí mejoran la precisión predictiva, pero que al nivel de la estrategia los

pronósticos simples ya logran la mayor parte de la reducción en la volatilidad de la volatilidad, y la ganancia adicional del ML es modesta en el mejor de los casos.

En resumen, la literatura reciente deja una brecha bastante consistente entre valor estadístico y valor económico: el ML suele pronosticar mejor, pero esa mejora se diluye al pasar del pronóstico a la cartera. Esa brecha es lo que queremos estudiar, sobre una cartera más simple que las de los antecedentes y con un protocolo completamente documentado.

6. Aporte esperado

El trabajo no propone una estrategia nueva: es una replicación con extensión, y creemos que eso es lo apropiado para esta área. La crítica de Cederburg et al. muestra que muchos resultados positivos de esta literatura no sobreviven a una implementación realista, así que replicar con un protocolo estricto aporta más que innovar sin ese cuidado. En concreto, vamos a:

1. Llevar la comparación de pronósticos del tipo de Lolic (2025) al terreno que ese trabajo no cubre: una estrategia invertible de SPY más activo libre de riesgo, con la regla de exposición de la literatura de targeting.
2. Comparar EWMA, GARCH, HAR y gradient boosting bajo el mismo protocolo temporal: mismas ventanas, misma información disponible en cada fecha, y validación purgada para gradient boosting.
3. Evaluar en dos niveles separados: el estadístico (QLIKE, RMSE, Diebold-Mariano) y el económico (distancia entre la volatilidad realizada y la objetivo, Sharpe, drawdown máximo, retornos extremos). La separación permite ubicar dónde se pierde la ventaja del ML, si es que se pierde.
4. Medir el efecto de cada fricción por separado: costos de transacción, rezago de ejecución, tope de exposición y frecuencia de rebalanceo, informando resultados brutos y netos.
5. Dejar el pipeline documentado y reproducible, desde los datos crudos hasta las tablas finales.

El flujo del trabajo va de los datos al pronóstico, del pronóstico a la exposición, y de la exposición al resultado económico. Cualquier desenlace nos sirve. Si la ventaja predictiva del modelo de machine learning llega a la cartera, la medimos. Si no llega, que es lo que la evidencia previa sugiere como más probable, habremos verificado ese resultado sobre el caso más simple posible y con un protocolo abierto.

7. Pitch preliminar

Una estrategia diaria sobre SPY que ajusta su exposición para mantener el riesgo constante, con el capital sobrante en un activo libre de riesgo. El insumo crítico es el pronóstico de volatilidad, y tres benchmarks econométricos (EWMA, GARCH, HAR) y un retador de machine learning. Primero respondemos cuál pronostica mejor fuera de muestra, con las métricas que corresponden a un objetivo que no se observa directamente; después, si esa ventaja se sostiene en una cartera con costos, rezagos y límites reales. La literatura sugiere que en ese pasaje la ventaja del machine learning se achica mucho; el objetivo del trabajo es medir esa brecha con un backtest estrictamente fuera de muestra y sin look-ahead bias, sin asumir el resultado de antemano.

Bibliografía

- Bongaerts, D., Kang, X. y van Dijk, M. A. (2020). "Conditional Volatility Targeting". *Financial Analysts Journal*, 76(4), 54–71.
- Bollerslev, T. (1986). "Generalized Autoregressive Conditional Heteroskedasticity". *Journal of Econometrics*, 31(3), 307–327.
- Cederburg, S., O'Doherty, M. S., Wang, F. y Yan, X. (2020). "On the Performance of Volatility-Managed Portfolios". *Journal of Financial Economics*, 138(1), 95–117.
- Christensen, K., Siggaard, M. y Veliyev, B. (2023). "A Machine Learning Approach to Volatility Forecasting". *Journal of Financial Econometrics*, 21(5), 1680–1727.
- Corsi, F. (2009). "A Simple Approximate Long-Memory Model of Realized Volatility". *Journal of Financial Econometrics*, 7(2), 174–196.
- Diebold, F. X. y Mariano, R. S. (1995). "Comparing Predictive Accuracy “*Journal of Business & Economic Statistics*, 13(3), 253–263.
- Díaz, J. D., Hansen, E. y Cabrera, G. (2024). "Machine-learning stock market volatility: Predictability, drivers, and economic value". *International Review of Financial Analysis*, 94, 103286.
- Engle, R. F. (1982). "Autoregressive Conditional Heteroscedasticity with Estimates of the Variance of United Kingdom Inflation". *Econometrica*, 50(4), 987–1007.
- Garman, M. B. y Klass, M. J. (1980). "On the Estimation of Security Price Volatilities from Historical Data". *Journal of Business*, 53(1), 67–78.
- Hansen, P. R. y Lunde, A. (2005). "A Forecast Comparison of Volatility Models: Does Anything Beat a GARCH(1,1)?". *Journal of Applied Econometrics*, 20(7), 873–889.
- Harvey, C. R., Hoyle, E., Korgaonkar, R., Rattray, S., Sargaison, M. y Van Hemert, O. (2018). "The Impact of Volatility Targeting". *Journal of Portfolio Management*, 45(1), 14–33.
- Hong, X. (2026). "Forecasting and Managing Volatility with Machine Learning". SSRN Working Paper N.º 6277518.
- J.P. Morgan/Reuters (1996). *RiskMetrics Technical Document*, 4.ª edición.
- Kilic, R. (2025). "Linear and Nonlinear Econometric Models Against Machine Learning Models: Realized Volatility Prediction". Finance and Economics Discussion Series 2025-061, Federal Reserve Board.

- Lolic, M. (2025). "Tree-Based Methods of Volatility Prediction for the S&P 500 Index". *Computation*, 13(4), 84.
- Moreira, A. y Muir, T. (2017). "Volatility-Managed Portfolios". *Journal of Finance*, 72(4), 1611–1644.
- Patton, A. J. (2011). "Volatility Forecast Comparison Using Imperfect Volatility Proxies". *Journal of Econometrics*, 160(1), 246–256.