Finanzas Computacionales

UCEMA, 2026



Tesina

Pronóstico de volatilidad del S&P 500 aplicado a una estrategia de volatility targeting

Alumnos: Andrés Otero y Ezequiel Telias

Índice

Abstract 3

Introducción 4

1. Motivación, literatura e hipótesis 5

2. Datos y proxy de volatilidad 8

3. Modelos y protocolo de estimación 12

   3.1 Modelos 12

   3.2 Evaluación cronológica fuera de muestra 13

4. Valor estadístico de los pronósticos 15

5. Valor económico en la estrategia de volatility targeting 18

   5.1 Reglas del backtest 18

   5.2 Caso base 19

   5.3 Alfa y diferencia de Sharpe 22

6. Robustez de los resultados 24

   6.1 Corte de entrenamiento y subperíodos 24

   6.2 Frecuencia de decisión y día ancla 25

   6.3 Variantes de la regla 27

7. Ejecución, costos y confiabilidad del backtest 30

   7.1 Convención de ejecución y desfase 30

   7.2 Costos, liquidez y capacidad 31

   7.3 Confiabilidad del backtest 32

8. Conclusiones 34

Anexos 36

   Anexo A. Hiperparámetros y grilla 36

   Anexo B. Derivaciones 36

   Anexo C. Repositorio y reproducibilidad 38

   Anexo D. Tablas adicionales 39

   Anexo E. Nota sobre convenciones 42

Bibliografía 44

Abstract

Este trabajo evalúa si la mayor precisión de un modelo de machine learning en el pronóstico de volatilidad se traduce en valor económico. Sobre datos diarios de SPY desde 2000, con la volatilidad realizada de Garman-Klass más overnight, comparamos EWMA, GARCH, HAR-RV y gradient boosting, y con los mismos pronósticos fijamos la exposición de una estrategia de volatility targeting sobre SPY y un activo libre de riesgo, con fricciones y un día de rezago en la ejecución.

El gradient boosting obtiene el menor QLIKE, con diferencias significativas, y mantiene esa ventaja con otro proxy, otros cortes de entrenamiento y un día de atraso, pero no la traslada a la cartera. Ninguna estrategia presenta un alfa estadísticamente distinguible de cero frente a SPY ni un ratio de Sharpe distinguible del pasivo o de las otras estrategias, antes o después de los costos del caso base, con los que el gradient boosting queda último. Su ventaja de precisión vale poco aun sin fricciones y se consume en turnover.

Introducción

La elección de un modelo de volatilidad suele apoyarse en su error de pronóstico. Cuando ese pronóstico determina cuánto capital se invierte, también importan las operaciones que genera y el momento en que pueden ejecutarse. Nos interesó estudiar esa relación porque permite evaluar el aporte de un modelo de machine learning a una decisión concreta de inversión. La pregunta de esta tesina es si el gradient boosting mejora la precisión frente a modelos econométricos y si esa mejora se traduce en un beneficio económicamente significativo en una estrategia de volatility targeting sobre SPY y un activo libre de riesgo.

El trabajo comenzó con la construcción de una base diaria y de una medida de volatilidad realizada que incorpora tanto el movimiento de la rueda como el salto entre sesiones. Sobre esa base comparamos EWMA, GARCH, HAR-RV y gradient boosting, y agregamos una variante del último con información del VIX. Cada pronóstico se genera con los datos disponibles hasta la fecha de decisión y se evalúa fuera de muestra. Después usamos esos mismos pronósticos para determinar la exposición a SPY, con una regla común que contempla un tope de apalancamiento, una banda de no-trade, costos y un rezago de ejecución. Incluimos como referencias el pasivo, que compra SPY y lo mantiene, y un targeting sin modelo. El recorrido termina con pruebas de robustez y una descomposición de las fricciones, para examinar cuánto depende el resultado del modelo y cuánto de las condiciones de implementación.

El capítulo 1, "Motivación, literatura e hipótesis", ubica la pregunta en la evidencia previa y presenta las hipótesis. El capítulo 2, "Datos y proxy de volatilidad", describe las fuentes, la muestra y el estimador utilizado. El capítulo 3, "Modelos y protocolo de estimación", explica las especificaciones y la evaluación cronológica fuera de muestra. Los capítulos 4 y 5, "Valor estadístico de los pronósticos" y "Valor económico en la estrategia de volatility targeting", presentan los resultados de precisión y de cartera. El capítulo 6, "Robustez de los resultados", examina otras ventanas de evaluación, frecuencias de decisión y variantes de la regla. El capítulo 7, "Ejecución, costos y confiabilidad del backtest", estudia el efecto de las fricciones y los límites del análisis. El capítulo 8 reúne las conclusiones. Los anexos contienen las fórmulas, los detalles de estimación, las tablas adicionales y la información necesaria para reproducir el trabajo.

1. Motivación, literatura e hipótesis

La volatilidad de los retornos varía mucho en el tiempo y es muy persistente, mientras que a horizontes cortos la variación del retorno esperado es despreciable, y su pronóstico es una de las áreas más activas y exitosas de la econometría de series de tiempo (Andersen et al., 2006). Por eso el pronóstico de volatilidad es el insumo de casi toda decisión de tamaño de posición, de control de riesgo y de valuación de derivados, y por eso es donde tiene sentido preguntar cuánto vale un modelo mejor.

En los últimos años los métodos de machine learning ganaron terreno en ese campo. Lolic (2025) encuentra que el random forest y el gradient boosting pronostican la volatilidad a un mes del S&P 500 fuera de muestra, en general, con menor error que EWMA y GARCH, y que agregar el VIX mejora al gradient boosting, y Hong (2026), que los árboles con boosting mejoran al HAR a una semana y a un mes, con poca mejora a un día. Díaz et al. (2024) encuentran que varios métodos de machine learning, con la regularización y las redes neuronales a la cabeza, superan al HAR a un mes aunque no a horizontes más largos. Hong y Díaz et al. observan además que esa ventaja rinde poco al pasar a una cartera, con una mejora a lo sumo modesta en el control de la volatilidad en Hong y sin ganancia económica sustancial en Díaz et al. Bollerslev et al. (2018), en cambio, encuentran ganancias de utilidad para su mejor modelo que sobreviven a costos realistas, aunque los costos reordenan los modelos según cuánto operan. Ninguno de los tres mide, con un mismo protocolo, cuánto de la ventaja de precisión se pierde en cada paso entre el pronóstico y el retorno. Entre la señal y el retorno realizado median la regla que transforma el pronóstico en una posición, los costos de operar, el rezago entre la decisión y la ejecución y la relación, débil y discutida, entre la volatilidad esperada y el retorno esperado. Cuánto pesa cada uno de esos factores en el retorno de la cartera sigue sin medirse, y Hong observa que la ventaja de los modelos no lineales se concentra en los períodos de volatilidad alta, sin medir qué pesa eso en el retorno de la cartera.

La forma más directa de convertir un pronóstico de volatilidad en retorno es el volatility targeting. Consiste en mantener en el activo riesgoso una fracción del patrimonio inversamente proporcional a la volatilidad pronosticada, de modo que la volatilidad del portafolio se mantenga cerca de un objetivo fijo. Moreira y Muir (2017) mostraron que una regla de ese tipo, con la exposición inversa a la varianza realizada del mes anterior y rebalanceo mensual, produce alfas positivos frente al activo sin gestionar para el mercado accionario y varios factores, y en el caso del mercado eleva el ratio de Sharpe del pasivo. Cederburg et al. (2020) confirmaron esos alfas, pero mostraron que la cartera gestionada por sí sola no supera sistemáticamente a la cartera sin gestionar y que, cuando la escala y la ponderación entre la cartera gestionada y la pasiva se estiman sólo con información disponible en tiempo real, la combinación rinde menos que el activo sin gestionar fuera de muestra. Liu et al. (2019) señalan que la aplicación habitual al mercado accionario usa información que no estaba disponible al decidir y encuentran que, corregido eso, la estrategia supera al mercado solo durante la crisis financiera. Harvey et al. (2018), que no imponen un tope de apalancamiento, encuentran que el targeting mejora el ratio de Sharpe en acciones y crédito y reduce la frecuencia de retornos extremos en todos los activos. Esa

literatura evalúa la regla con estimaciones sencillas de la volatilidad, la varianza realizada del mes anterior en Moreira y Muir y un promedio exponencial de los retornos diarios al cuadrado en Harvey et al., así que deja sin responder qué parte del resultado depende de la calidad del pronóstico.

Esta tesina junta las dos preguntas en un solo protocolo. Pronosticamos la volatilidad diaria del S&P 500, con el ETF SPY, con cuatro modelos elegidos por su papel en la comparación. El promedio móvil exponencial de RiskMetrics es la referencia sin parámetros estimados, el GARCH(1,1) de Bollerslev (1986) el modelo paramétrico y el HAR-RV de Corsi (2009) el modelo de volatilidad realizada. El cuarto es un gradient boosting sobre un conjunto chico de variables que incluye los regresores del HAR, el retorno con signo y medidas de asimetría y rango. Una variante del gradient boosting agrega la información del VIX. Los mismos pronósticos alimentan la misma estrategia de volatility targeting sobre SPY y un activo libre de riesgo, con un objetivo de volatilidad de 10% anual, apalancamiento acotado a 1.5 veces, una banda de no-trade, costos de transacción y un día de rezago entre la decisión y la ejecución. En las estrategias agregamos un targeting sin modelo, que en las tablas figura como Trailing 21 días y usa la varianza realizada de los últimos 21 días como pronóstico, para separar el valor de pronosticar del valor del targeting en sí. Los modelos se comparan primero como pronósticos, con dos funciones de pérdida, QLIKE y la raíz del error cuadrático medio (RMSE), y con el test de Diebold y Mariano (1995), siguiendo a Patton (2011) para la elección de pérdidas robustas a un proxy ruidoso de la varianza. Después se comparan como estrategias, con el alfa de la regresión de spanning y la diferencia del ratio de Sharpe contra el pasivo y entre modelos. Hong (2026), que recorre el mismo camino de pronóstico a portafolio con gradient boosting y con una estrategia que también apunta a 10% anual con rebalanceo diario y un tope de apalancamiento de 1.5 veces, es el punto de comparación directo, aunque evalúa las estrategias sólo por su control de la volatilidad, sin costos ni ratio de Sharpe. Bollerslev et al. (2018) aportan la medida de utilidad realizada que valúa la precisión de un pronóstico en unidades de riqueza, y que en este trabajo calculamos sin costos.

La estrategia sigue a Moreira y Muir (2017) en lo esencial, con una implementación distinta. Ellos escalan la exposición por la inversa de la varianza realizada del mes anterior, con una constante calibrada sobre toda la muestra para igualar la volatilidad del pasivo, y rebalancean mensualmente. Nuestro peso es el cociente entre la volatilidad objetivo y la volatilidad pronosticada, se recalcula a diario y se opera solo cuando se aleja del peso vigente más que la banda. Escalar por la volatilidad en lugar de la varianza reduce a la mitad la elasticidad del peso al pronóstico y es menos agresivo en los extremos. El tope de 1.5 veces lo tomamos de la variante de Moreira y Muir que impone una restricción de margen estándar. Elegimos el horizonte diario porque el costo de operar a diario es parte del mecanismo que queremos medir y porque esperábamos que a horizonte mensual los pronósticos de los cuatro modelos se parecieran y la comparación perdiera sentido.

Tres hipótesis ordenan el protocolo. La primera es predictiva y se decide con el error de pronóstico, la segunda es económica y se decide con el portafolio antes de costos de

transacción, y la tercera es operativa y pregunta si las dos anteriores sobreviven a las fricciones de llevar la estrategia a la práctica.

Hipótesis 1 (H1), predictiva: el gradient boosting pronostica la volatilidad diaria de SPY con menor error que EWMA, GARCH y HAR-RV, medido con QLIKE y RMSE contra la varianza realizada diaria, estimada con Garman-Klass más overnight.

Hipótesis 2 (H2), económica: antes de costos de transacción, la estrategia de volatility targeting que usa el mejor pronóstico mantiene la volatilidad realizada más cerca del objetivo y obtiene un ratio de Sharpe mayor que el de mantener SPY sin gestionar y que el de la misma estrategia con los otros modelos.

Hipótesis 3 (H3), operativa: esas mejoras sobreviven a los costos de transacción, al rezago de ejecución y al turnover, con pesos construidos únicamente con información disponible al momento de decidir.

El aporte del trabajo es medir la brecha entre valor estadístico y valor económico. La literatura la documenta y propone conjeturas sobre su mecanismo, pero no la mide con un solo protocolo, con los mismos pronósticos, el mismo portafolio y las mismas fricciones, separando cada paso del pronóstico al retorno. Las tres hipótesis están formuladas para que puedan fallar, y desde el inicio dejamos abierta la posibilidad de que el machine learning no agregue valor económico.

2. Datos y proxy de volatilidad

SPY, el ETF que replica al S&P 500, es el único activo riesgoso durante toda la muestra, y el resto del patrimonio queda en un activo libre de riesgo remunerado a la tasa de las letras del Tesoro a tres meses. No hay selección de activos, y toda la variación del portafolio está en el peso entre los dos. El VIX entra solo como predictor de la variante ampliada del gradient boosting.

De SPY usamos los precios de apertura, máximo, mínimo y cierre sin ajustar, el cierre ajustado y la serie de dividendos. Los primeros alimentan el estimador de volatilidad realizada. Los cocientes dentro del día, máximo sobre mínimo y cierre sobre apertura, no cambian con el ajuste por dividendos, así que los precios crudos no pierden información. El único cociente que cruza días es el salto entre el cierre previo y la apertura, y preferimos corregirlo nosotros con la serie de dividendos antes que usar el cierre ajustado de Yahoo Finance, que es la única serie ajustada que entrega la fuente y que además se recalcula con cada pago. El precio de cierre ajustado produce los retornos de la estrategia, simples para el backtest y logarítmicos como insumo de los modelos. La serie de dividendos en efectivo por acción, en su fecha ex-dividendo, corrige el término overnight del estimador. Las tres series vienen de Yahoo Finance con una descarga automatizada. El VIX viene de la misma fuente y la tasa de tres meses, de la serie DGS3MO de FRED.

El activo libre de riesgo funciona como una cuenta remunerada. La parte del patrimonio que no está en SPY gana cada día el rendimiento de las letras del Tesoro a tres meses, y cuando el peso en SPY supera uno la diferencia se financia a esa misma tasa más un spread. FRED publica esa tasa como un rendimiento anualizado, y para convertirlo en un retorno diario lo capitalizamos a 252 días hábiles, de modo que el retorno del día es (1 + y) elevado a 1/252, menos uno. La tasa que remunera el día t es la observada el día anterior, porque el retorno de la cuenta entre el cierre de t−1 y el cierre de t se devenga a una tasa que ya era conocida al comienzo de ese tramo. Usar la tasa del propio día t sería remunerar el tramo con un dato que todavía no existía cuando se tomó la posición. Ni la tasa ni el VIX cotizan todos los días hábiles de SPY, porque la tasa falta en feriados bancarios y el calendario del VIX puede no coincidir con el del ETF. En esos días repetimos el último valor disponible, hasta un máximo de cinco días hábiles. Si falta un dato por más tiempo, el procedimiento se interrumpe y registra la fecha. En la muestra la tasa se repitió en 48 días, el VIX en ninguno, y ningún hueco superó el límite.

La muestra va del 4 de enero de 2000 al 30 de junio de 2026, 6661 días hábiles. El primer día hábil del año 2000 se pierde porque el estimador necesita el cierre del día anterior. La ventana inicial de entrenamiento cubre de 2000 a 2009, 2514 días, y la evaluación fuera de muestra arranca el 4 de enero de 2010 y comprende 4147 días de pronóstico. Las estrategias operan desde el 5 de enero de 2010 y suman 4146 días, uno menos, porque el primer peso se ejecuta al cierre del 4 de enero y devenga retorno recién desde el día siguiente. El fin de muestra es fijo para todas las corridas, incluidas las de robustez con el corte de entrenamiento en 2008 y en 2012.

Como la volatilidad no se observa, el estimador que la reemplaza define a la vez el target con el que se entrenan HAR-RV y gradient boosting y el valor realizado contra el que se evalúan los seis pronósticos, los de los cuatro modelos, la variante con VIX y el targeting sin modelo. Usamos el estimador de Garman y Klass (1980) sobre los precios del día más el salto overnight, Garman-Klass más overnight en adelante. La varianza diaria total del día t es

$$\sigma^2(t) = 0.5\,[\ln(H(t)/L(t))]^2 - (2\ln 2 - 1)\,[\ln(C(t)/O(t))]^2 + [\ln((O(t) + D(t)) / C(t-1))]^2$$

donde O, H, L y C son la apertura, el máximo, el mínimo y el cierre sin ajustar, y D es el dividendo por acción que se descuenta del precio en la fecha ex-dividendo, cero el resto de los días. Los dos primeros sumandos forman el estimador de Garman y Klass, que aprovecha el rango del día y la distancia entre apertura y cierre, y bajo sus supuestos es varias veces más eficiente que el retorno al cuadrado. El tercero es el retorno logarítmico entre el cierre anterior y la apertura, al cuadrado. Sumar las dos partes da la varianza de todo el día, de cierre a cierre, que es la cantidad que EWMA y GARCH, estimados sobre retornos de cierre a cierre, pronostican. Sin el término overnight el target sería la varianza de la rueda y los cuatro modelos no pronosticarían la misma cantidad.

El ajuste por dividendo en el término overnight es necesario porque los precios son crudos. En cada fecha ex-dividendo la apertura cae mecánicamente en el monto del dividendo, y ese salto no es volatilidad. Sin la corrección entraría como varianza en las 107 fechas ex-dividendo de la muestra, cuatro veces por año, y contaminaría sistemáticamente el target de entrenamiento y la referencia de evaluación. El término overnight tiene además una limitación de precisión. Es un único retorno al cuadrado, mucho más ruidoso que el componente intradiario, que combina cuatro precios, y por eso el estimador total es menos preciso que el término de Garman y Klass solo.

Un día plano daría varianza cero, que QLIKE no admite. El Anexo B describe los dos resguardos del estimador para ese caso, que en la muestra no se activaron nunca.

El target de evaluación es la estimación cruda de cada día, sin suavizar. Patton (2011) muestra que QLIKE y el error cuadrático medio son robustos a un proxy ruidoso siempre que sea condicionalmente insesgado, de modo que el ranking esperado de los modelos contra el proxy coincide con el ranking contra la varianza verdadera. Suavizar el target con promedios de varios días filtraría información entre días y el proxy dejaría de ser condicionalmente insesgado para la varianza de un día, que es la condición bajo la cual Patton (2011) demuestra que el ranking se conserva. Los promedios de 1, 5 y 22 días entran como regresores del HAR y del gradient boosting, no como target.

Descartamos el estimador de Yang y Zhang (2000), que incorpora el salto overnight con una ponderación óptima pero está definido sobre una ventana de varios días y no da la estimación diaria que el diseño necesita. Descartamos también los datos de alta frecuencia, que permitirían una varianza realizada más precisa, porque conseguirlos con historia completa desde 2000, limpiarlos y construir el estimador sobre ellos nos excedía en tiempo, y para la pregunta que planteamos los datos diarios alcanzan.

El período fuera de muestra fue mucho más favorable para el inversor pasivo que la ventana de entrenamiento (Tabla 1), con un retorno anual medio de 14.8% contra 1.6% y menor volatilidad, 17.1% contra 22.4%. La ventana de entrenamiento contiene el estallido de la burbuja tecnológica y la crisis de 2008. La ventana de evaluación contiene la crisis del euro, el episodio de volatilidad de febrero de 2018, la pandemia de 2020 y el mercado bajista de 2022, y aun así cierra con menor volatilidad media y mayor retorno. La asimetría pasa de positiva a negativa entre las dos ventanas y la curtosis en exceso supera diez en ambas, así que los retornos diarios tienen colas pesadas en todo el período. La volatilidad realizada media, anualizada, es de 15.3% en toda la muestra, con una mediana bastante menor, 12.2%, porque la distribución de la volatilidad es asimétrica. La media de 15.3% promedia desvíos diarios y por eso queda debajo de la volatilidad de los retornos. La raíz de la varianza media, 19.5%, casi coincide con el 19.3% de los retornos de cierre a cierre, la cantidad que el estimador debe reproducir. El máximo diario, 196.3% anualizado, corresponde al 16 de marzo de 2020.

Tabla 1: Estadísticas descriptivas de SPY y de la volatilidad realizada

Estadístico	2000-2026	Entrenamiento 2000-2009	Fuera de muestra 2010-2026
Días	6661	2514	4147
Retorno anual medio	9.8%	1.6%	14.8%
Volatilidad anual	19.3%	22.4%	17.1%
Asimetría	0.04	0.34	-0.33
Curtosis en exceso	12.05	10.52	12.00
Vol. GK + overnight media	15.3%	17.9%	13.6%
Vol. GK + overnight mediana	12.2%	14.6%	11.0%
Vol. GK + overnight máxima	196.3%	153.9%	196.3%
Raíz de la varianza GK + overnight media	19.5%	22.6%	17.4%

Fuente: elaboración propia en base a datos de Yahoo Finance.

En el Gráfico 1, con el precio ajustado de SPY en escala logarítmica arriba y la volatilidad realizada anualizada abajo, día por día y como raíz de su varianza media de 21 días, se ven los dos rasgos que motivan el trabajo. La volatilidad se agrupa en episodios que persisten semanas o meses, y los picos coinciden con caídas del precio. La línea vertical marca el inicio de la evaluación fuera de muestra.

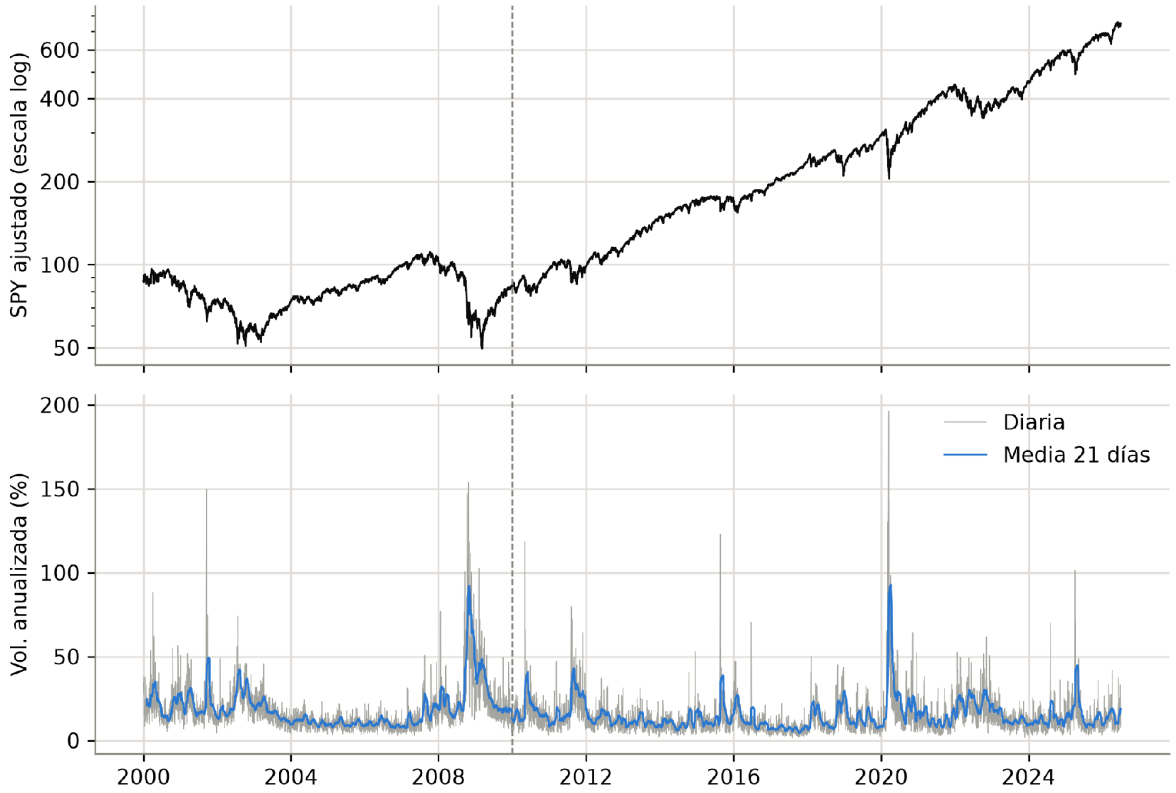


Gráfico 1: Precio de SPY y volatilidad realizada Garman-Klass más overnight, 2000-2026

Fuente: elaboración propia en base a datos de Yahoo Finance.

3. Modelos y protocolo de estimación

3.1 Modelos

EWMA y GARCH se construyen sobre retornos logarítmicos de cierre a cierre y los otros cuatro sobre la varianza Garman-Klass más overnight, así que la comparación supone covarianza condicional nula entre el retorno overnight y el intradiario. Bajo ese supuesto los seis pronostican la misma varianza diaria total del día siguiente.

EWMA pronostica la varianza combinando la varianza previa con el retorno logarítmico del día al cuadrado, con ponderaciones 0.94 y 0.06, el valor diario de RiskMetrics (J.P. Morgan/Reuters, 1996). La recursión parte de la varianza muestral de los retornos de la primera ventana de entrenamiento y conserva ese punto de partida durante toda la evaluación. Elegimos no estimar la ponderación porque EWMA es la referencia sin parámetros estimados, y estimarla le quitaría ese papel.

El GARCH(1,1) de Bollerslev (1986) agrega una constante a esa recursión y estima por separado la respuesta al último retorno y la persistencia de la varianza. La media es constante, para concentrar la especificación en la dinámica de la volatilidad, y las innovaciones siguen una distribución de t de Student, como en Bollerslev (1987), con grados de libertad estimados en cada ajuste. Entre estimaciones mensuales se calcula cada día el residuo respecto de la media estimada y se actualiza la varianza condicional con los parámetros vigentes. Para facilitar la convergencia del ajuste, los retornos se expresan en porcentaje y el pronóstico se convierte de nuevo a volatilidad diaria en decimales.

El HAR-RV de Corsi (2009), HAR en adelante, representa la persistencia con tres horizontes de varianza realizada. Corsi lo formula sobre la volatilidad realizada y señala que puede escribirse sobre la varianza o sobre su logaritmo, y usamos esta última versión. La log-varianza del día siguiente se explica por una constante y los logaritmos de las medias aritméticas de la varianza realizada de 1, 5 y 22 días, con ventanas que incluyen el día de decisión y el logaritmo tomado después de promediar. Los coeficientes se estiman por mínimos cuadrados.

El gradient boosting, GBM en adelante, está implementado con LightGBM (Ke et al., 2017) y ajusta árboles sucesivos para reducir el error cuadrático medio de la log-varianza del día siguiente, y admite respuestas no lineales e interacciones entre los predictores. Sus nueve variables son las tres medias de varianza del HAR en logaritmos, la log-varianza del día anterior, el retorno logarítmico con signo del día de decisión, las sumas de retornos de 5 y 22 días, la semivarianza negativa de 22 días y la varianza de Parkinson (1980) del día, estas dos últimas en logaritmos. Incluimos la varianza de Parkinson para que el modelo tenga el rango entre máximo y mínimo como predictor separado, ya que Garman-Klass más overnight lo mezcla con el movimiento entre apertura y cierre y con el salto overnight. La semivarianza promedia el cuadrado de los retornos negativos y asigna cero a los demás días, y un piso positivo permite tomar el logaritmo cuando esa medida o el rango son nulos. Todas las variables se construyen con datos conocidos al cierre de la decisión.

La variante GBM + VIX, en la línea de Lolic (2025), agrega el nivel del VIX expresado como log-varianza diaria, el cambio diario de esa log-varianza y su diferencia con la log-varianza realizada del día. Esta última aproxima la prima de varianza, aunque compara la volatilidad implícita del VIX con la realizada de un solo día. Las tres se construyen con el cierre del VIX del día de decisión y el del día anterior, así que el pronóstico de t+1 no usa ningún valor del VIX posterior al cierre de t. La variante conserva la pérdida, la grilla y el procedimiento de estimación del GBM base, en las mismas fechas de estimación.

El targeting sin modelo, Trailing 21 días en las tablas, pronostica con la raíz de la media aritmética de la varianza Garman-Klass más overnight de los últimos 21 días, incluido el día de decisión, y recoge la persistencia de la volatilidad sin estimar parámetros.

HAR y los dos GBM comparten la corrección al pasar de log-varianza a varianza. Exponenciar el pronóstico en logaritmos devuelve la mediana condicional de la varianza, no su media. Con errores normales en logaritmos y varianza constante, la media se recupera sumando la mitad de la varianza de los residuos antes de exponenciar, y la raíz cuadrada da la volatilidad. Esa varianza se estima sobre un bloque de validación al final de la ventana de entrenamiento, descrito en la sección 3.2, con un modelo estimado sobre el bloque anterior. Preferimos estos residuos a los del ajuste completo porque los residuos de un boosting sobre su propia muestra de entrenamiento subestiman la varianza real y dejarían el pronóstico sesgado a la baja. Después cada modelo se reestima sobre toda la ventana y conserva la corrección obtenida en validación. Las ecuaciones de las seis especificaciones y de la corrección están en el Anexo B.

3.2 Evaluación cronológica fuera de muestra

La ventana inicial, de 2000 a 2009, produce el pronóstico para el primer día hábil de 2010. Desde entonces, con cada cierre los seis modelos actualizan su estado y pronostican el día siguiente, y el último día hábil de cada mes, GARCH, HAR y los dos GBM se reestiman con toda la historia disponible hasta ese cierre, sin descartar observaciones antiguas. El EWMA y el targeting sin modelo reconstruyen su estado en esas mismas fechas sin estimar nada. En los seis casos la reconstrucción reemplaza el estado previo, de modo que el día de la estimación entra una sola vez.

En cada ajuste del GBM, el primer 80% de las observaciones con predictores y target completos sirve para estimar y el tramo final para validar, con 22 días excluidos entre ambos bloques, en línea con el purgado y el embargo que López de Prado (2018) recomienda para separar entrenamiento y validación en series financieras. Ese embargo iguala la mayor ventana de los predictores e impide que entrenamiento y validación compartan días de datos originales. Es más distancia de la que necesita un target a un día, para el que bastaría una observación entre bloques, a cambio de 22 observaciones de validación. El HAR usa el mismo corte y el mismo embargo para estimar la varianza residual de su corrección lognormal.

La grilla del GBM recorre la tasa de aprendizaje y el número máximo de hojas por árbol. Para cada combinación el ajuste se detiene cuando el error de validación deja de mejorar.

Se elige la combinación con menor error y se ajusta de nuevo sobre la ventana completa con el número de árboles obtenido en validación, así que el mismo bloque decide la detención temprana, la combinación elegida y la varianza residual de la corrección lognormal. La búsqueda se repite en cada estimación mensual. Los valores de la grilla, la regla de detención y la semilla aleatoria están en el Anexo A.

Al estimar HAR y los dos GBM con información hasta el cierre de t, la última observación de entrenamiento vincula los predictores de t−1 con la varianza realizada en t, y los datos de t actualizan los predictores del pronóstico de t+1. Cada pronóstico se registra en la fecha del día que anticipa y se compara con la varianza realizada de esa fecha, de modo que los seis se evalúan sobre los mismos 4147 días, sin recalcular pronósticos pasados con parámetros elegidos después.

4. Valor estadístico de los pronósticos

Los seis pronósticos se comparan con QLIKE como pérdida principal y RMSE como secundaria, las dos calculadas sobre varianzas contra la varianza Garman-Klass más overnight de cada día, para responder la pregunta de H1, si el gradient boosting pronostica la volatilidad diaria de SPY con menor error que EWMA, GARCH y HAR. QLIKE es la pérdida de cuasi verosimilitud gaussiana y depende solo del cociente entre la varianza realizada y la pronosticada, así que no tiene unidades, pesa igual un error relativo en un día calmo que en uno turbulento y castiga más subestimar la varianza que sobreestimarla. RMSE mide la distancia en unidades de varianza diaria y queda dominado por los días de mayor volatilidad. Por su escala, la Tabla 2 lo muestra multiplicado por diez mil. QLIKE es la pérdida principal por esa estabilidad y porque es una de las pérdidas robustas a un proxy ruidoso (Patton, 2011). Sus fórmulas están en el Anexo B.

El QLIKE del GBM es 0.379, contra 0.419 del HAR, 0.444 del GARCH, 0.497 del EWMA y 0.524 del targeting sin modelo, Trailing 21 días en la tabla, y la variante con VIX baja a 0.352 (Tabla 2). RMSE conserva el orden, con 3.35 para el HAR, 3.03 para el GBM y 2.97 para el GBM + VIX.

La significancia de esas diferencias se prueba con el test de Diebold y Mariano (1995) sobre la pérdida diaria de cada modelo menos la del GBM base, con el error estándar de Newey y West (1987) y el rezago de su regla automática (Newey y West, 1994), porque los episodios de volatilidad hacen que varios días seguidos favorezcan al mismo modelo. El estadístico es positivo cuando el modelo pierde más que el GBM y vale 4.48 para el HAR, 7.98 para el GARCH, 8.13 para el EWMA y 7.25 para el targeting sin modelo, y −4.74 para el GBM + VIX, que pierde menos que el GBM. Los cinco valores p son menores que 0.001 sin corrección por multiplicidad y quedan debajo del umbral de Bonferroni al 5% para cinco comparaciones, 0.01. El orden y la significancia se repiten con el corte de entrenamiento en 2008 y en 2012.

Tabla 2: Evaluación de pronósticos contra la varianza Garman-Klass más overnight

Modelo	QLIKE	RMSE (x10^4)	DM vs GBM	p	Utilidad realizada (% anual)
Trailing 21 días	0.524	3.83	7.25	<0.001	2.88
EWMA	0.497	3.63	8.13	<0.001	2.97
GARCH(1,1)	0.444	3.38	7.98	<0.001	3.13
HAR-RV	0.419	3.35	4.48	<0.001	3.17
GBM	0.379	3.03			3.22
GBM + VIX	0.352	2.97	-4.74	<0.001	3.29

Fuente: elaboración propia en base a datos de Yahoo Finance.

HAR y los dos GBM se entrenan sobre la log-varianza del mismo proxy que se usa para evaluar, mientras que EWMA y GARCH reciben retornos de cierre a cierre. Como esa asimetría puede favorecer a los primeros, repetimos QLIKE con el retorno logarítmico de cierre a cierre al cuadrado como proxy alternativo, conservando los pronósticos y las fechas. El orden entre GARCH, HAR y los dos GBM se mantiene (Tabla 3), con el piso de varianza

aplicado en los 58 días de retorno casi nulo del proxy alternativo. Solo intercambian posiciones el EWMA y el targeting sin modelo, con pérdidas casi iguales, así que el orden no es un efecto de evaluar sobre la misma cantidad con la que se entrenaron HAR y los dos GBM. El estadístico del HAR contra el GBM baja a 3.89 y el del GBM + VIX queda en −3.42, ambos más chicos en valor absoluto que con el proxy principal, con valores p menores que 0.001 en todas las comparaciones.

Tabla 3: Ranking de pronósticos con el retorno al cuadrado como proxy alternativo

Modelo	QLIKE, GK + overnight	QLIKE, retorno al cuadrado	DM vs GBM, retorno al cuadrado	p	Días en el piso, retorno al cuadrado
Trailing 21 días	0.524	1.635	6.57	<0.001	58
EWMA	0.497	1.638	6.68	<0.001	58
GARCH(1,1)	0.444	1.581	6.58	<0.001	58
HAR-RV	0.419	1.532	3.89	<0.001	58
GBM	0.379	1.492			58
GBM + VIX	0.352	1.467	-3.42	<0.001	58

Fuente: elaboración propia en base a datos de Yahoo Finance.

Entre enero y junio de 2020 los pronósticos del GARCH y del GBM suben después de los primeros saltos de febrero y marzo sin alcanzar los picos de la volatilidad realizada diaria, y en la caída posterior el GARCH desciende de forma gradual mientras el GBM cambia más de un día al otro (Gráfico 2).

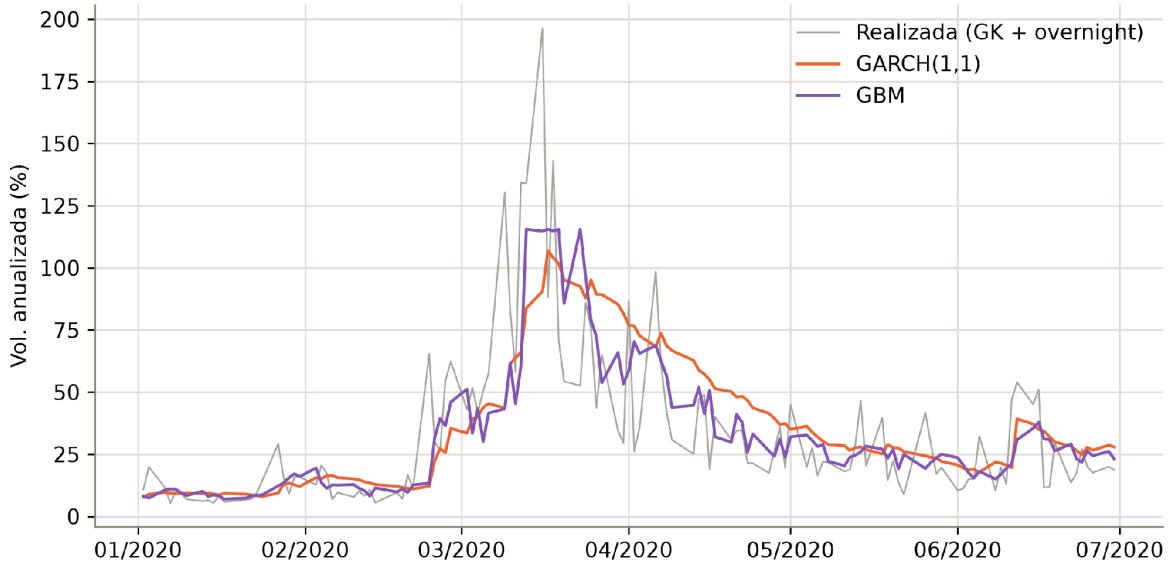


Gráfico 2: GARCH y GBM contra la volatilidad realizada, enero a junio de 2020

Fuente: elaboración propia en base a datos de Yahoo Finance.

La última columna de la Tabla 2 traduce la precisión a riqueza con la utilidad realizada de Bollerslev et al. (2018), la de un inversor media-varianza con coeficiente de aversión al riesgo 2 que dimensiona su posición en un activo de ratio de Sharpe 0.4 a partir del pronóstico de cada modelo, sin costos ni restricciones, aplicada aquí a pronósticos diarios

en lugar de los mensuales de ese trabajo. El HAR obtiene 3.17% de riqueza por año, el GBM 3.22% y el GBM + VIX 3.29%, así que la ventaja de precisión del GBM sobre el HAR, clara en QLIKE, vale 0.05 puntos porcentuales por año. Como la medida usa la raíz del proxy, no tiene la robustez al ruido que Patton (2011) garantiza para QLIKE, y por eso la tomamos como descriptiva.

5. Valor económico en la estrategia de volatility targeting

5.1 Reglas del backtest

El peso en SPY es el cociente entre la volatilidad objetivo y la volatilidad pronosticada para el día siguiente, w = σ_obj / σ̂, con la volatilidad objetivo de 10% anual convertida a diaria dividiéndola por la raíz de 252. El peso se acota al intervalo entre 0 y 1.5. No hay posiciones cortas, y el tope de apalancamiento, el cap, es de 1.5 veces el patrimonio y se vuelve operativo cuando el pronóstico cae por debajo de dos tercios del objetivo. El remanente del patrimonio queda en el activo libre de riesgo y, cuando el peso supera uno, la diferencia se financia a esa tasa más un spread de 50 puntos básicos anuales, convertido a diario con la misma capitalización que la tasa.

El peso w(t) se decide con el cierre de t, porque todos los modelos necesitan ese cierre, el EWMA y el GARCH para el retorno del día y el HAR, los dos GBM y el targeting sin modelo (Trailing 21 días en las tablas) para el término de cierre del estimador de varianza. Decidimos ejecutar al cierre siguiente porque el pronóstico necesita el cierre definitivo de t y una orden en ese mismo cierre tendría que enviarse antes de conocerlo. La orden se ejecuta entonces al cierre de t+1 y la posición devenga el retorno de t+1 a t+2:

$$r(t+2) = w(t) \cdot ret(t+2) + cash(t+2) - costo(t+2)$$

donde ret es el retorno simple de SPY sobre el cierre ajustado, rf el retorno diario del activo libre de riesgo, cash(t+2) es (1 − w(t)) · rf(t+2) si el peso no supera uno y −(w(t) − 1) · (rf(t+2) + spread) si lo supera, y el costo es proporcional al peso efectivamente operado. Esta convención rige en todos los resultados del documento, tanto en el caso base como en los ejercicios de robustez. La literatura de volatility targeting aplica el peso al retorno del período que sigue a la decisión, como Moreira y Muir (2017) con la varianza del mes anterior y el retorno del mes que empieza. En frecuencia diaria eso equivale a la orden en el mismo cierre, con w(t) aplicado a ret(t+1), y en el capítulo 7 corremos esa convención sobre los mismos pronósticos para medir cuánto cuesta el día de diferencia.

El peso objetivo se recalcula todos los días, pero se opera solo cuando se aleja del peso vigente más de 5 puntos porcentuales. Entre operaciones el peso vigente se desplaza con los retornos relativos de SPY y del activo libre de riesgo, sobre el patrimonio neto de costos. Al romper la banda se opera hasta el peso objetivo completo. El primer día fuera de muestra se ejecuta al objetivo sin condición de banda. El cap actúa como segundo disparador, porque si ese desplazamiento deja el peso vigente por encima de 1.5, se opera aunque la banda no se haya roto. Ese caso aparece solo después de caídas de SPY. Ignorando la tasa, con 100 de patrimonio y peso 1.5 la cartera tiene 150 en SPY y 50 de deuda. Si SPY sube 10%, la posición pasa a 165, el patrimonio a 115 y el peso baja a 1.43. Si SPY cae 10%, la posición pasa a 135, el patrimonio a 85 y el peso sube a 1.59.

Los costos de transacción son de 2 puntos básicos por operación sobre el monto operado, con sensibilidad a 5 y 10. Las dos referencias contra las que se mide cada modelo son el pasivo, que compra SPY el primer día, paga solo ese costo inicial y por eso figura con un

turnover de 0.06 veces por año en las tablas, y el targeting sin modelo, que corre con las mismas reglas que los modelos.

Medimos el turnover como 252 veces el cambio medio diario del peso en valor absoluto, en veces el capital por año, y el control del objetivo con el vol-of-vol de Hong (2026), la raíz de la media del cuadrado de la diferencia entre la volatilidad anualizada de los últimos 21 días de retornos logarítmicos de la estrategia y el objetivo de 10%, en puntos porcentuales. A pesar del nombre, y a diferencia del vol-of-vol de Harvey et al. (2018), que es el desvío estándar de la volatilidad móvil, esta medida penaliza tanto que la volatilidad oscile como que se quede lejos del objetivo, como el propio Hong señala. El Sharpe, el drawdown y las colas, medidas con los cinco peores días, la asimetría y la curtosis en exceso, siguen las definiciones habituales, y las fórmulas de todas las métricas están en el Anexo B.

Para la inferencia usamos la regresión de Moreira y Muir (2017), que Cederburg et al. (2020) llaman regresión de spanning y que explica el exceso de retorno de la estrategia con el exceso de retorno de SPY, con el estadístico t del alfa calculado con errores de Newey y West (1987) y el rezago de su regla automática (Newey y West, 1994). No reportamos la ganancia de utilidad de Moreira y Muir porque es el cuadrado del appraisal ratio de esa misma regresión dividido por el cuadrado del Sharpe del activo sin gestionar, y corresponde a la combinación óptima de la cartera gestionada con la pasiva, no a la estrategia sola. La diferencia de ratios de Sharpe se prueba con el estadístico studentizado de Ledoit y Wolf (2008). Su valor p sale de un bootstrap estacionario por bloques (Politis y Romano, 1994) de 1000 réplicas, en lugar del bootstrap circular que usan Ledoit y Wolf, con el largo de bloque elegido por la regla de Politis y White (2004) con la corrección de Patton et al. (2009).

5.2 Caso base

El caso base, en la Tabla 4, corre con decisión diaria, objetivo de 10%, cap de 1.5, banda de 5 puntos porcentuales, 2 puntos básicos por operación y ejecución al cierre siguiente a la decisión, sobre los 4146 días de retorno de estrategia, del 5 de enero de 2010 al 30 de junio de 2026. El pasivo va primero y las seis estrategias siguen ordenadas por QLIKE, de peor a mejor.

Tabla 4: Estrategias en el caso base

Estrategia	QLIKE	Sharpe neto	Vol realizada	Vol-of-vol (pp)	Drawdown máx.	Turnover anual
Pasivo		0.773	17.2%	10.22	-33.7%	0.06x
Trailing 21 días	0.524	0.735	10.9%	3.46	-16.0%	3.8x
EWMA	0.497	0.738	10.6%	3.32	-15.5%	4.2x
GARCH(1,1)	0.444	0.744	10.0%	2.66	-14.1%	6.8x
HAR-RV	0.419	0.760	9.9%	2.45	-15.0%	15.2x
GBM	0.379	0.732	10.1%	2.35	-15.7%	23.4x
GBM + VIX	0.352	0.732	9.9%	2.30	-14.9%	23.1x

Fuente: elaboración propia en base a datos de Yahoo Finance y FRED.

La precisión se traslada al control del riesgo, porque en el período completo el orden por vol-of-vol reproduce el orden por QLIKE, con 3.46 puntos porcentuales para el targeting sin modelo, 3.32 para el EWMA, 2.66 para el GARCH, 2.45 para el HAR, 2.35 para el GBM y 2.30 para el GBM + VIX, contra 10.22 del pasivo. En esta muestra un pronóstico más preciso mantiene la volatilidad más cerca del objetivo, aunque ese orden no se conserva en todos los subperíodos.

Todas las reglas reducen la exposición, incluida la que no pronostica, así que esa reducción no depende del pronóstico. Las seis estrategias operan con una volatilidad realizada entre 9.9% y 10.9% contra 17.2% del pasivo, y todas dejan el drawdown máximo en menos de la mitad, entre 14.1% y 16.0% contra 33.7%. El GARCH tiene el menor drawdown y el GBM el segundo mayor, detrás del targeting sin modelo, así que este orden no sigue al de QLIKE. Las colas, en la Tabla 13 del Anexo D, mejoran de la misma forma. El peor día del pasivo es una caída de 10.9% y el de las estrategias va de 3.6% a 4.8%, y la curtosis en exceso baja de 12.0 a entre 1.9 y 3.8. La asimetría, en cambio, empeora, de −0.33 en el pasivo a entre −0.66 y −0.85 en las estrategias. Nuestra lectura, que no medimos, es que la regla recorta los días extremos de los dos signos y que la cartera entra expuesta a los episodios que el pronóstico todavía no captó.

El Sharpe neto, en cambio, no sigue ni a la precisión ni a la exposición, y las seis estrategias quedan en un rango angosto, entre 0.732 y 0.760, por debajo del 0.773 del pasivo. El HAR es el más alto, el GARCH y el EWMA quedan en 0.744 y 0.738, y los dos GBM empatan en 0.732 a pesar de ser los más precisos. Antes de costos, también en la Tabla 13, el HAR alcanza 0.791 y los dos GBM 0.779, y los tres superan al pasivo, mientras el GARCH, el EWMA y el targeting sin modelo quedan entre 0.742 y 0.758. Los dos órdenes difieren porque los dos GBM operan 23 veces su capital por año, el HAR 15, el GARCH 7, y el EWMA y el targeting sin modelo alrededor de 4, y a 2 puntos básicos ese turnover le cuesta 0.047 de Sharpe al GBM y 0.031 al HAR, contra 0.008 al EWMA.

El peso que sale del GBM cambia más de un día al otro que el que sale del EWMA, y la banda de 5 puntos porcentuales no absorbe esa diferencia, porque los GBM operan unos 160 días por año con un cambio medio de peso de entre 14 y 15 puntos porcentuales y el EWMA unos 53 días con 8 puntos. Con poco más de la mitad del riesgo del pasivo, las estrategias del targeting sin modelo, del HAR y del GBM terminan con una riqueza neta de entre 3.9 y 4.3 veces el capital inicial, frente a 8.8 del pasivo, y con drawdowns que no superan el 16% (Gráfico 3).

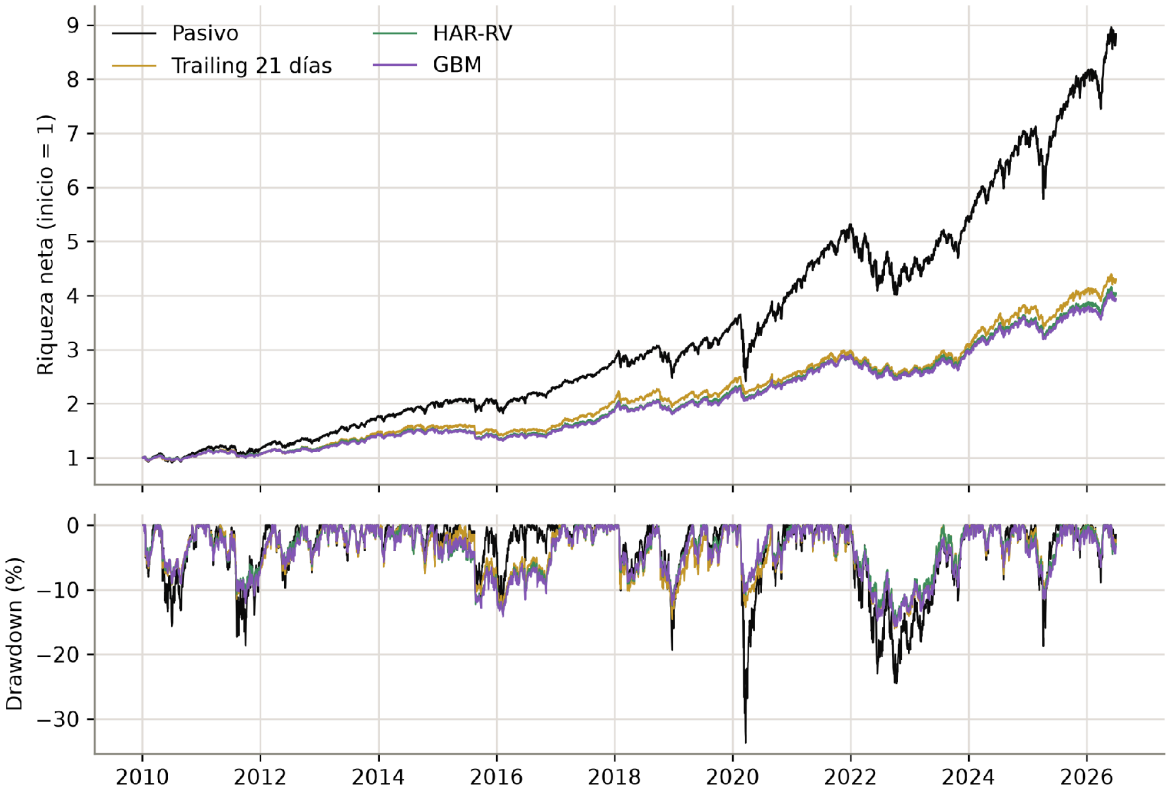


Gráfico 3: Riqueza acumulada neta y drawdown, caso base

Fuente: elaboración propia en base a datos de Yahoo Finance y FRED.

A lo largo de la muestra, la volatilidad móvil de 21 días del pasivo va de un mínimo cercano a 3% a más de 90% en el pico de marzo y abril de 2020 (Gráfico 4). La del targeting sin modelo y la del GBM se mantienen alrededor de 10%, se separan del objetivo sobre todo al comienzo de los episodios de volatilidad, y la del GBM queda más cerca del objetivo que la del targeting sin modelo.

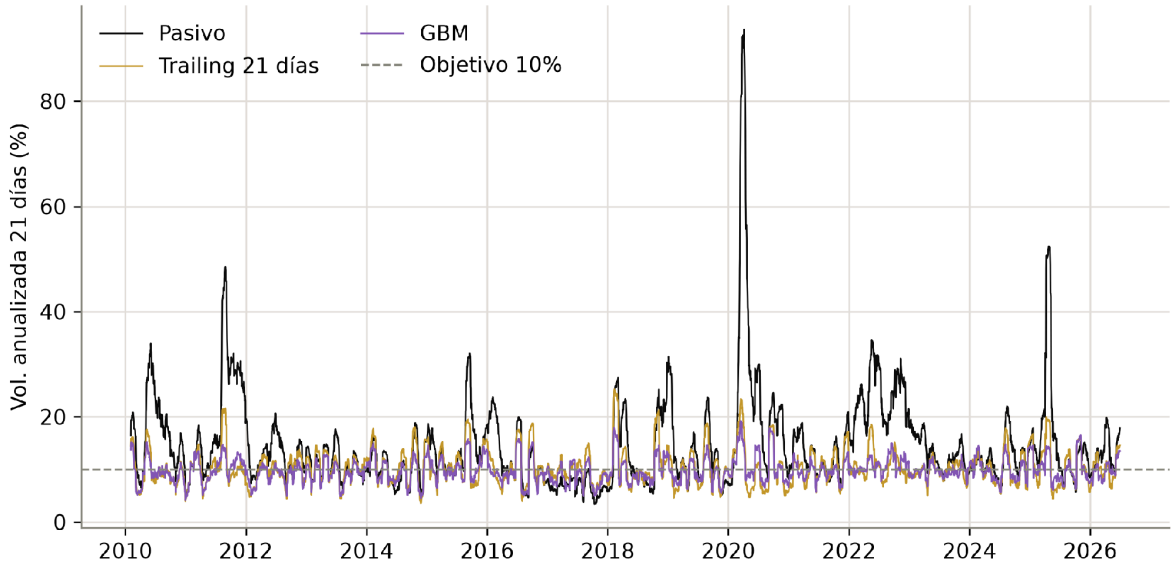


Gráfico 4: Volatilidad móvil de 21 días contra el objetivo, caso base

Fuente: elaboración propia en base a datos de Yahoo Finance y FRED.

5.3 Alfa y diferencia de Sharpe

Sobre retornos brutos los alfas anuales de la regresión de spanning contra SPY van de 0.7% a 1.1% (Tabla 5), con estadísticos t entre 0.52 y 0.91 y valores p entre 0.37 y 0.60. Las diferencias de Sharpe contra el pasivo van de −0.031 a +0.017 con valores p entre 0.78 y 0.96. Sobre retornos netos los alfas bajan a entre 0.6% y 0.8%, los t a entre 0.47 y 0.66, y las seis diferencias de Sharpe pasan a ser negativas, entre −0.041 y −0.013, con valores p de 0.72 o más. Ninguna estrategia agrega un alfa distinguible de cero sobre una exposición fija a SPY, ni antes ni después de costos, y ninguna tiene un ratio de Sharpe distinguible del pasivo.

Tabla 5: Regresión de spanning y diferencia de Sharpe contra el pasivo

Modelo	Alfa anual, bruto	t NW, bruto	p alfa, bruto	Dif. Sharpe vs pasivo, bruto	p Sharpe, bruto	Alfa anual, neto	t NW, neto	p alfa, neto	Dif. Sharpe vs pasivo, neto	p Sharpe, neto
Trailing 21 días	0.7%	0.52	0.60	-0.031	0.78	0.6%	0.47	0.64	-0.038	0.73
EWMA	0.7%	0.55	0.58	-0.027	0.80	0.6%	0.49	0.63	-0.035	0.75
GARCH(1,1)	0.8%	0.67	0.51	-0.015	0.89	0.7%	0.56	0.58	-0.029	0.79
HAR-RV	1.1%	0.91	0.37	0.017	0.88	0.8%	0.66	0.51	-0.013	0.91
GBM	1.1%	0.83	0.40	0.006	0.96	0.6%	0.48	0.63	-0.041	0.74
GBM + VIX	1.1%	0.82	0.41	0.006	0.95	0.6%	0.47	0.64	-0.041	0.72

Fuente: elaboración propia en base a datos de Yahoo Finance y FRED.

Tampoco hay diferencias significativas entre modelos. De las 21 comparaciones pareadas entre las siete series (Tabla 14 del Anexo D), el valor p más bajo es 0.22 sobre la serie bruta, para el HAR contra el targeting sin modelo, y 0.39 neto de costos, para el HAR contra el GBM. Con 21 comparaciones por serie, cualquier corrección por multiplicidad vuelve más

exigente el umbral, así que con un valor p mínimo de 0.22 la conclusión no depende de la corrección.

6. Robustez de los resultados

6.1 Corte de entrenamiento y subperíodos

El resultado del caso base podría depender de la ventana. Repetimos la estimación de los seis pronósticos y el backtest con el corte de entrenamiento en 2008 y en 2012, así que la evaluación fuera de muestra empieza en 2009 y en 2013 en lugar de 2010, con el mismo fin de muestra. El orden por QLIKE y por vol-of-vol de la Tabla 6 es el mismo en los tres cortes, con el GBM + VIX primero, el GBM segundo y el HAR tercero, y los cinco estadísticos de Diebold y Mariano contra el GBM conservan su signo, entre 3.73 y 8.13 en valor absoluto, con valores p menores que 0.001. El orden por Sharpe, en cambio, depende del corte. Con el corte en 2008 los dos GBM ocupan los dos últimos lugares, igual que en el caso base, y con el corte en 2012 suben al segundo y tercer lugar, detrás del HAR, que es el mejor modelo en los tres cortes y con el corte en 2008 queda apenas por encima del pasivo, 0.784 contra 0.783. El valor p más bajo contra el pasivo es 0.66, con el corte en 2012.

Tabla 6: QLIKE, Sharpe y vol-of-vol por corte de entrenamiento

Muestra	Medida	Trailing 21 días	EWMA	GARCH(1,1)	HAR-RV	GBM	GBM + VIX	Pasivo	p mínimo
Entrenamiento hasta 2008	QLIKE	0.511	0.486	0.435	0.412	0.374	0.349		
	DM vs GBM	7.16	7.99	7.82	4.43		-4.75		
	p DM	<0.001	<0.001	<0.001	<0.001		<0.001		
	Sharpe	0.768	0.769	0.766	0.784	0.756	0.758	0.783	0.82
	Vol-of-vol (pp)	3.38	3.25	2.62	2.41	2.31	2.27	10.73	
Entrenamiento hasta 2009 (base)	QLIKE	0.524	0.497	0.444	0.419	0.379	0.352		
	DM vs GBM	7.25	8.13	7.98	4.48		-4.74		
	p DM	<0.001	<0.001	<0.001	<0.001		<0.001		
	Sharpe	0.735	0.738	0.744	0.760	0.732	0.732	0.773	0.72
	Vol-of-vol (pp)	3.46	3.32	2.66	2.45	2.35	2.30	10.22	
Entrenamiento hasta 2012	QLIKE	0.536	0.509	0.451	0.420	0.382	0.352		
	DM vs GBM	7.12	7.84	7.72	3.73		-4.55		
	p DM	<0.001	<0.001	<0.001	<0.001		<0.001		
	Sharpe	0.765	0.751	0.746	0.792	0.777	0.782	0.801	0.66
	Vol-of-vol (pp)	3.53	3.43	2.73	2.47	2.37	2.33	10.15	

Fuente: elaboración propia en base a datos de Yahoo Finance y FRED.

En las dos mitades del caso base el mercado cambia más que las estrategias (Tabla 7). El Sharpe del pasivo cae de 0.931 en 2010-2017 a 0.671 en 2018-2026, el de las seis estrategias cae con él, y el orden entre modelos se invierte entre mitades. En la primera el EWMA y el GARCH van adelante y los dos GBM atrás. En la segunda el HAR, con 0.684, es el único que supera al pasivo, los dos GBM lo siguen y el EWMA queda último. Ninguna diferencia contra el pasivo es significativa en ninguna mitad, con valores p mínimos de 0.42 y 0.59. El vol-of-vol del pasivo sube de 7.53 a 12.25 puntos porcentuales entre mitades, así que en la segunda el mercado se aleja más del objetivo de 10% y el targeting tiene más que

corregir. El vol-of-vol sigue el orden de QLIKE del período completo en 2010-2017. En 2018-2026 el vol-of-vol del GBM queda apenas debajo del del GBM + VIX, 2.33 contra 2.36, la única inversión de ese orden en los cortes y los subperíodos.

Tabla 7: Sharpe y vol-of-vol por subperíodo

Muestra	Medida	Trailing 21 días	EWMA	GARCH(1,1)	HAR-RV	GBM	GBM + VIX	Pasivo	p mínimo
2010-2017	Sharpe	0.868	0.908	0.897	0.844	0.815	0.838	0.931	0.42
	Vol-of-vol (pp)	3.20	2.96	2.55	2.44	2.38	2.25	7.53	
2018-2026	Sharpe	0.615	0.585	0.610	0.684	0.660	0.638	0.671	0.59
	Vol-of-vol (pp)	3.69	3.63	2.77	2.47	2.33	2.36	12.25	
Sin 2020	Sharpe	0.751	0.757	0.742	0.754	0.724	0.725	0.818	0.26
	Vol-of-vol (pp)	3.32	3.17	2.58	2.39	2.24	2.22	8.08	

Fuente: elaboración propia en base a datos de Yahoo Finance y FRED.

Excluir el año 2020 aleja a las estrategias del pasivo (Tabla 7), cuyo Sharpe sube de 0.773 a 0.818 mientras el de los modelos se mueve entre −0.008 y +0.019 respecto del caso base, con un valor p mínimo de 0.26.

6.2 Frecuencia de decisión y día ancla

Las variantes de decisión semanal y mensual toman el peso con el pronóstico a un día hecho el último día hábil de la semana o del mes, lo ejecutan al cierre siguiente y lo mantienen hasta la decisión siguiente. En estas variantes preferimos esa asimetría deliberada entre el horizonte del pronóstico y el período de tenencia antes que introducir pronósticos a una semana o a un mes, que cambiarían el objeto de la comparación. La banda de 5 puntos porcentuales rige en cada fecha de decisión y el cap se evalúa solo en esas fechas, de modo que respecto del caso base cambian la cantidad de decisiones por año y el momento en que se controla el cap. Entre fechas el peso mantenido puede superar el cap después de una caída de SPY, y en las dos variantes lo hace en pocos días, entre 0 y 65 de los 4146 según el modelo y la frecuencia, y por poco, con un peso máximo de 1.59 (Tabla 15 del Anexo D). Decidimos no convertir el cap en un disparador diario porque agregaría operaciones fuera de las fechas de decisión y volvería a mezclar la frecuencia con el control del riesgo, que en esta robustez queremos mantener separados.

El turnover del GBM baja de 23.4 veces el capital por año con decisión diaria a 8.6 con semanal y a 2.7 con mensual, y el Sharpe no lo acompaña (Tabla 8). Con decisión semanal, anclada en el último día hábil de la semana, las seis estrategias quedan entre 0.706 y 0.727, debajo del caso base. Con decisión mensual suben el EWMA, el GARCH y el targeting sin modelo (Trailing 21 días), entre 0.010 y 0.020, mientras el HAR cae a 0.695 y los dos GBM a 0.721 y 0.717, y ninguna fila llega al 0.773 del pasivo. Los que más pierden con decisión mensual, el HAR y los dos GBM, son los que más operan con decisión diaria, así que operar menos no los acerca al pasivo.

Tabla 8: Sharpe neto y turnover por variante de la regla

Variante	Medida	Trailing 21 días	EWMA	GARCH(1,1)	HAR-RV	GBM	GBM + VIX	Pasivo	p mínimo
Caso base	Sharpe neto	0.735	0.738	0.744	0.760	0.732	0.732	0.773	0.72
	Turnover anual	3.8x	4.2x	6.8x	15.2x	23.4x	23.1x	0.06x	
Vol objetivo 15%	Sharpe neto	0.745	0.749	0.773	0.762	0.750	0.739	0.773	0.74
	Turnover anual	4.0x	4.9x	8.9x	17.0x	22.7x	22.7x	0.06x	
Vol objetivo 20%	Sharpe neto	0.758	0.811	0.829	0.779	0.762	0.768	0.773	0.52
	Turnover anual	2.9x	3.1x	6.4x	11.6x	15.0x	14.6x	0.06x	
Sin cap	Sharpe neto	0.740	0.734	0.744	0.760	0.731	0.736	0.773	0.73
	Turnover anual	4.1x	4.6x	6.8x	15.9x	24.7x	24.4x	0.06x	
Regla por varianza	Sharpe neto	0.602	0.567	0.569	0.641	0.589	0.564	0.773	0.21
	Turnover anual	6.2x	7.1x	12.0x	23.6x	35.1x	34.9x	0.06x	
Corte de vol 30%	Sharpe neto	0.712	0.711	0.705	0.640	0.648	0.656	0.773	0.33
	Turnover anual	4.0x	4.8x	7.8x	17.0x	25.3x	25.1x	0.06x	
Corte de vol 20%	Sharpe neto	0.614	0.643	0.658	0.619	0.669	0.593	0.773	0.25
	Turnover anual	4.9x	5.8x	9.7x	20.5x	28.5x	27.8x	0.06x	
Pronóstico a dos días	Sharpe neto	0.735	0.738	0.752	0.755	0.766	0.762	0.773	0.73
	Turnover anual	3.8x	4.2x	6.5x	18.0x	18.8x	18.1x	0.06x	
Decisión semanal	Sharpe neto	0.712	0.718	0.727	0.706	0.719	0.710	0.773	0.50
	Turnover anual	3.4x	3.3x	4.7x	7.0x	8.6x	8.7x	0.06x	
Decisión mensual	Sharpe neto	0.746	0.748	0.764	0.695	0.721	0.717	0.773	0.50
	Turnover anual	2.4x	2.1x	2.6x	2.8x	2.7x	2.6x	0.06x	
Banda 0 pp	Sharpe neto	0.747	0.740	0.753	0.757	0.721	0.727	0.773	
	Turnover anual	5.2x	6.3x	9.3x	17.9x	25.6x	25.2x	0.06x	
Banda 2.5 pp	Sharpe neto	0.746	0.743	0.759	0.753	0.722	0.725	0.773	
	Turnover anual	4.4x	5.2x	8.4x	17.0x	24.9x	24.6x	0.06x	
Banda 10 pp	Sharpe neto	0.721	0.726	0.753	0.762	0.741	0.705	0.773	
	Turnover anual	3.2x	3.2x	4.9x	11.5x	19.6x	19.4x	0.06x	
Cap 2x	Sharpe neto	0.739	0.735	0.744	0.760	0.730	0.734	0.773	
	Turnover anual	4.0x	4.6x	6.8x	15.9x	24.7x	24.4x	0.06x	
Cap 3x	Sharpe neto	0.740	0.734	0.744	0.760	0.731	0.736	0.773	
	Turnover anual	4.1x	4.6x	6.8x	15.9x	24.7x	24.4x	0.06x	

Fuente: elaboración propia en base a datos de Yahoo Finance y FRED.

El resultado semanal depende del día en que se decide (Tabla 9). Repetimos la variante anclando la decisión en cada día de la semana, con todo lo demás igual. Decidiendo los martes, el HAR y los dos GBM superan al pasivo, con el GBM en 0.803, los jueves el GBM

llega a 0.793, y los miércoles los mismos dos GBM son los peores de la tabla, con 0.680 y 0.661. Los viernes, la fila de decisión semanal de la Tabla 8, los seis quedan debajo del caso base. Los valores p mínimos contra el pasivo van de 0.23 a 0.78. Entre los cinco días se hacen 105 comparaciones de a pares entre estrategias, y una sola queda por debajo de 0.05, el HAR contra el GBM + VIX los miércoles, con valor p de 0.040 neto de costos (Tabla 16 del Anexo D). Con 105 comparaciones se esperan unas cinco por azar, así que no leemos esa diferencia como una ventaja del HAR.

Tabla 9: Decisión semanal según el día ancla

Muestra	Medida	Trailing 21 días	EWMA	GARCH(1,1)	HAR-RV	GBM	GBM + VIX	p mínimo
Lunes	Sharpe	0.740	0.723	0.743	0.763	0.752	0.758	0.64
	Vol-of-vol (pp)	3.84	3.76	3.13	2.90	2.91	2.74	
Martes	Sharpe	0.764	0.746	0.769	0.799	0.803	0.788	0.78
	Vol-of-vol (pp)	3.88	3.87	3.30	3.02	2.93	2.84	
Miércoles	Sharpe	0.735	0.719	0.711	0.746	0.680	0.661	0.23
	Vol-of-vol (pp)	4.04	4.05	3.54	3.17	3.21	3.14	
Jueves	Sharpe	0.740	0.726	0.744	0.766	0.793	0.770	0.61
	Vol-of-vol (pp)	3.89	3.84	3.20	2.92	2.75	2.70	
Viernes	Sharpe	0.712	0.718	0.727	0.706	0.719	0.710	0.50
	Vol-of-vol (pp)	4.04	3.82	3.24	3.07	2.99	3.03	

Fuente: elaboración propia en base a datos de Yahoo Finance y FRED.

El vol-of-vol cambia menos que el Sharpe con el día ancla. En los cinco días, el HAR y los dos GBM tienen los valores más bajos, entre 2.70 y 3.21 puntos porcentuales, el GARCH queda en el medio y el EWMA y el targeting sin modelo arriba, entre 3.76 y 4.05. Dentro de esos grupos el orden cambia, porque el HAR controla mejor que el GBM los lunes y los miércoles, el GBM mejor que el GBM + VIX los viernes y el EWMA peor que el targeting sin modelo los miércoles. Todos los valores semanales superan a los diarios de la Tabla 4, y esa diferencia mide el costo de decidir una vez por semana con un pronóstico a un día.

6.3 Variantes de la regla

Con objetivo de 15% el GARCH iguala al pasivo (Tabla 8), 0.773 en los dos casos, y los otros cinco quedan debajo. Con 20% lo superan el GARCH, con 0.829, el EWMA, con 0.811, y el HAR, con 0.779, mientras los dos GBM y el targeting sin modelo quedan entre 0.758 y 0.768. Ninguna de esas diferencias es significativa, con un valor p mínimo contra el pasivo de 0.52, aunque a ese objetivo el GARCH sí supera al targeting sin modelo con valor p de 0.038 neto (Tabla 16), la única diferencia entre modelos por debajo de 0.05 en las filas de la Tabla 8 que tienen valor p. Subir el objetivo escala todos los pesos y vuelve operativo el cap. Con el objetivo del caso base el cap rige entre 0.5% y 3.0% de los días según el modelo, y con 20% rige entre el 50.5% y el 55.4% de los días (Tabla 15) y aplana el peso, y el turnover del GBM baja a 15.0. Con el cap activo, el GARCH y el EWMA son los que más suben, y es de esperar que el cap anule gran parte de la precisión de los GBM. En la otra

dirección, subir el cap a 2 o a 3 veces o quitarlo mueve el Sharpe de cada modelo en 0.005 como máximo con el objetivo de 10%, porque a ese nivel el cap casi no se toca.

Sin banda el GBM opera 25.6 veces su capital por año, con una banda de 2.5 puntos porcentuales opera 24.9, con 5 puntos 23.4 y con 10 puntos 19.6, y en ninguna de esas filas el mejor modelo alcanza al pasivo. El orden entre modelos cambia de una banda a otra, porque sin banda el targeting sin modelo supera al EWMA y con 10 puntos el GBM supera al EWMA, entre otros cruces, pero el mejor modelo de cada fila sigue siendo el HAR o el GARCH y queda entre 0.011 y 0.016 debajo del pasivo.

Escalar el peso por la inversa de la varianza pronosticada, la forma funcional de Moreira y Muir (2017) con nuestro objetivo y nuestra frecuencia, empeora a las seis estrategias, con Sharpe entre 0.564 y 0.641, y el turnover sube entre 50% y 76% según el modelo, hasta 35.1 veces el capital por año en el GBM. Llevar el peso a cero cuando el pronóstico anualizado supera 30% o 20%, que convierte la regla en una de salida del mercado, también pierde para los seis, con el peor Sharpe en 0.593 y el mejor en 0.712. Para los seis modelos y en los dos umbrales, los días que la regla deja afuera rinden en promedio más que los que mantiene, entre 17.3 y 36.2 puntos básicos por día frente a entre 4.3 y 5.4 con el umbral de 30%, y entre 9.5 y 13.3 frente a entre 4.3 y 5.0 con el de 20% (Tabla 15). Un pronóstico construido con el cierre de t solo puede marcar la volatilidad alta después de que se realizó, así que las salidas probablemente llegan después de la caída.

Fijar el peso con un pronóstico a dos días, hecho en t para el retorno de t+2 que el peso efectivamente devenga, sube el Sharpe del GBM de 0.732 a 0.766 y el del GBM + VIX a 0.762, mueve poco al GARCH y al HAR y no cambia al EWMA ni al targeting sin modelo. Para esta variante el HAR y los dos GBM se reestiman con el target a dos días, el GARCH itera su recursión un paso más, y el EWMA y el targeting sin modelo repiten su pronóstico a un día porque no cambia con el horizonte. Es la única variante de la Tabla 8 en la que los dos GBM pasan al frente de los otros modelos, y aun así quedan debajo del pasivo. Entre las variantes implementables, los dos GBM solo lo superan con decisión semanal los martes, y el GBM también los jueves, sin significancia.

Separamos los 4147 días de pronóstico en quintiles por la volatilidad realizada del propio día y repartimos la ganancia de QLIKE de cada par entre ellos (Tabla 10). La partición usa la volatilidad realizada del día que se pronostica, que ninguna regla conoce al decidir. La ganancia del GBM sobre el HAR está en los días calmos, con el 54% en el quintil más calmo y el 2% en el más volátil, y sobre el GARCH el reparto es 57% y 17%. Sobre el EWMA y sobre el targeting sin modelo la ganancia sí está en el quintil más volátil, con 53% y 62%, y la del GBM + VIX sobre el GBM también, con 68%. En el quintil más volátil el QLIKE medio del GBM es 0.715, apenas debajo del 0.719 del HAR y muy por encima de sus propios 0.180 y 0.205 en el tercer y el cuarto quintil. En esos días solo el VIX le agrega precisión al GBM. Hong (2026) encuentra, en cambio, que la ventaja de los modelos no lineales sobre el HAR está sobre todo en los períodos de volatilidad alta.

Tabla 10: QLIKE y ganancia del GBM por quintil de volatilidad realizada

Medida	Modelo	Q1 (más calmo)	Q2	Q3	Q4	Q5 (más volátil)
QLIKE medio	Trailing 21 días	0.653	0.285	0.216	0.300	1.168
	EWMA	0.688	0.301	0.209	0.257	1.030
	GARCH(1,1)	0.744	0.299	0.187	0.218	0.769
	HAR-RV	0.669	0.294	0.203	0.212	0.719
	GBM	0.559	0.234	0.180	0.205	0.715
	GBM + VIX	0.547	0.226	0.176	0.186	0.625
Participación en la ganancia	GBM sobre Trailing 21 días	12.9%	7.0%	4.8%	13.1%	62.2%
	GBM sobre EWMA	21.8%	11.3%	4.8%	8.8%	53.3%
	GBM sobre GARCH(1,1)	57.1%	20.2%	1.9%	3.9%	16.9%
	GBM sobre HAR-RV	54.2%	29.5%	10.9%	3.4%	2.0%
	GBM + VIX sobre GBM	8.9%	6.1%	3.5%	13.9%	67.6%

Fuente: elaboración propia en base a datos de Yahoo Finance.

Esa distribución encaja con el mayor turnover de los GBM. Un pronóstico que acierta más en los días calmos parece mover el peso justo donde la regla tiene más capital expuesto, con un costo por cada ajuste y poco cambio en el riesgo de la cartera, porque la volatilidad que corrige es baja. Hong (2026) describe el mismo mecanismo desde el lado del control de riesgo, porque con un peso proporcional a la inversa del pronóstico un error del mismo tamaño mueve más la exposición cuando la volatilidad es baja.

7. Ejecución, costos y confiabilidad del backtest

7.1 Convención de ejecución y desfase

La Tabla 11 descompone el Sharpe del caso base según el día al que se aplica el peso decidido con el cierre de t. Arranca sin fricciones, agrega el cap, la banda y los costos de a uno sobre la convención implementable hasta llegar al caso base, y cierra con la orden en el mismo cierre con esas fricciones y con el pronóstico a dos días sin ellas.

Tabla 11: Sharpe según la convención de ejecución y las fricciones

Convención	Trailing 21 días	EWMA	GARCH(1,1)	HAR-RV	GBM	GBM + VIX
Peso aplicado al retorno del día de la decisión (contrafactual)	0.979	1.072	1.315	1.325	2.588	2.771
Orden al mismo cierre de la decisión	0.811	0.782	0.806	0.850	0.824	0.825
Orden al cierre siguiente (implementable)	0.762	0.749	0.771	0.796	0.773	0.784
+ cap	0.756	0.752	0.772	0.794	0.772	0.778
+ banda	0.742	0.746	0.758	0.791	0.779	0.779
+ costos (caso base)	0.735	0.738	0.744	0.760	0.732	0.732
Orden al mismo cierre con cap, banda y costos	0.784	0.760	0.774	0.801	0.775	0.772
Orden al cierre siguiente, pronóstico a dos días, sin fricciones	0.762	0.749	0.775	0.799	0.798	0.804

Fuente: elaboración propia en base a datos de Yahoo Finance y FRED.

Aplicar el peso al retorno del propio día de la decisión, cuya volatilidad el pronóstico ya incorpora, no es una estrategia posible, y lo reportamos para medir cuánto vale esa información. Respecto de la fila siguiente vale entre 0.17 y 0.51 de Sharpe para el EWMA, el GARCH, el HAR y el targeting sin modelo, Trailing 21 días en las tablas, y entre 1.8 y 1.9 para los dos GBM, que llegan a 2.59 y 2.77. Los dos GBM son los únicos que usan el retorno con signo del día como predictor, así que en esa fila su peso se aplica a un retorno cuyo signo el pronóstico ya vio, y probablemente por eso se despegan de los otros cuatro.

La orden en el mismo cierre con el que se calcula el pronóstico, la convención de la literatura, da sin fricciones 0.850 para el HAR, 0.824 y 0.825 para los dos GBM y 0.782 para el EWMA. Con las fricciones del caso base deja al HAR, al targeting sin modelo, al GBM y al GARCH entre 0.774 y 0.801, apenas por encima del 0.773 del pasivo y sin que ninguna de esas diferencias sea significativa (Tabla 16). Bajo nuestra convención, la orden al cierre siguiente, el retraso de un día cuesta entre 0.033 y 0.054 de Sharpe sin fricciones, menos para el EWMA y el GARCH y más para el HAR, el GBM y el targeting sin modelo, un costo del mismo tamaño que las diferencias de Sharpe entre modelos.

Medido como pronóstico, el retraso sube el QLIKE entre 8.6% y 9.9% en el EWMA, el GARCH, el HAR y el targeting sin modelo y más de 16% en los dos GBM, sin cambiar el orden entre modelos ni la significancia al 5% de las diferencias contra el GBM (Tabla 17 del

Anexo D), aunque la del HAR, con valor p de 0.03, deja de pasar el umbral corregido de 0.01. Un GBM con un día de atraso, con QLIKE 0.440, pronostica peor que un HAR a tiempo, con 0.419, así que el día de retraso cuesta más precisión que toda la ventaja del GBM sobre el HAR.

Fijar el peso con un pronóstico construido para el día del retorno recupera en Sharpe, sin fricciones, la mitad del costo del retraso en los dos GBM, 0.025 de 0.051 y 0.020 de 0.041, y casi nada en los otros cuatro. En QLIKE, en cambio, el EWMA y el targeting sin modelo no cambian con el horizonte, mientras que el GARCH, el HAR y los dos GBM recuperan entre 3% y 12% de la precisión perdida, y solo en el HAR esa mejora es significativa. Estos resultados sugieren que al llegar un día tarde se pierde sobre todo la información del último cierre y que el horizonte para el que se entrena el modelo pesa poco.

Construimos además dos oráculos, pronósticos que usan la volatilidad del día en que la posición está abierta, para acotar cuánto podría ganar un pronóstico perfecto. El oráculo diario toma como pronóstico la volatilidad Garman-Klass más overnight de ese mismo día, y el oráculo de 21 días la raíz de la varianza media de ese día y los 20 siguientes, de modo que conoce el régimen del mes pero nada de cada día en particular. Los dos pasan por el mismo backtest con el mismo cap, la misma banda y los mismos costos. Son solo un diagnóstico, con la orden en el mismo cierre y sobre los 4127 días comunes hasta el 1 de junio de 2026, porque rezagarlos un día les quitaría justamente la información futura que los define (Tabla 18 del Anexo D). Con esa convención y esa muestra el GBM da 0.809 y el pasivo 0.788. El oráculo diario da un Sharpe neto de 2.06 y el de 21 días, de 1.83. Si se ordenan los días por la volatilidad realizada del propio día, el quintil más volátil rinde −14 puntos básicos en promedio, y ordenándolos por el pronóstico del GBM rinde +9 (Tabla 19 del Anexo D).

Aleatorizar el signo de los retornos centrados, en 100 réplicas, conserva la magnitud de cada movimiento centrado, la serie de volatilidad realizada y los seis pronósticos originales. En ese contrafactual los seis modelos rinden entre 0.22 y 0.27 de Sharpe por encima del pasivo, contra entre −0.006 y +0.047 en los datos reales, y la ventaja del oráculo de 21 días sobre el GBM cae de 1.03 a menos de 0.05. El resultado es compatible con que la relación contemporánea entre volatilidad y dirección del retorno explique buena parte de esa brecha. El ejercicio es descriptivo, porque mantener los pronósticos originales al cambiar los retornos altera también su relación con la historia que los generó y la trayectoria de pesos y operaciones de la cartera.

7.2 Costos, liquidez y capacidad

Subiendo los costos de transacción a 5 puntos básicos, los dos GBM pasan a ser los últimos, con 0.662 y 0.663, y a 10 bajan a 0.546 y quedan por debajo de cada uno de los otros cuatro, con diferencias significativas al 5% sin corregir por multiplicidad y valores p entre 0.004 y 0.024 (Tabla 16). El EWMA y el targeting sin modelo apenas se mueven, con 0.727 y 0.724 a 5 puntos básicos y 0.707 los dos a 10, y el HAR queda entre los GBM y los otros tres modelos en los dos niveles (Tabla 12). Desde 5 puntos básicos el orden por

Sharpe es casi el inverso del orden por QLIKE, y a ningún nivel de costos un modelo se acerca al pasivo.

Tabla 12: Sharpe neto por costo de transacción

Costo por operación	Trailing 21 días	EWMA	GARCH(1,1)	HAR-RV	GBM	GBM + VIX	Pasivo
2 bps	0.735	0.738	0.744	0.760	0.732	0.732	0.773
5 bps	0.724	0.727	0.724	0.714	0.662	0.663	0.773
10 bps	0.707	0.707	0.690	0.635	0.546	0.546	0.773

Fuente: elaboración propia en base a datos de Yahoo Finance y FRED.

Para SPY, los 2 puntos básicos del caso base deberían cubrir el spread y un deslizamiento razonable en el cierre, y 5 y 10 funcionan como estrés para días de pánico o para tamaños que empiecen a mover el precio. Con esta liquidez el costo proporcional es la aproximación habitual, y no modelamos el impacto según el tamaño. Medida contra el volumen medio en dólares de SPY de las últimas 21 ruedas, la capacidad mediana de las seis estrategias en los días en que operan, el capital con el que la orden tomaría el 1% del volumen, va de 2.14 a 3.45 mil millones de dólares y es menor para los modelos que más operan (Tabla 15). Para tamaños mayores el límite lo pondría el volumen de la subasta de cierre, una fracción del total.

7.3 Confiabilidad del backtest

Ninguna decisión usa información posterior al cierre con el que se toma, y la alineación entre peso y retorno, incluido el tramo apalancado, está comprobada con las pruebas del Anexo C. Los datos salen de una copia congelada con fecha y huella, los costos y el fondeo se descuentan y la grilla del GBM se elige con datos anteriores a cada decisión. El ajuste del GBM es determinista y no submuestrea observaciones ni variables, así que la semilla fijada en el Anexo A no cambia el resultado.

El principal riesgo que queda es la muestra, SPY entre 2010 y 2026, un período dominado por un mercado alcista con episodios de volatilidad cortos. Harvey et al. (2018), con muestras que empiezan décadas antes y pasan por 2008, encuentran que el targeting reduce la frecuencia de retornos extremos y mejora el Sharpe en acciones. En esta muestra aparece la reducción de los extremos, que también logra el targeting sin modelo, pero no la mejora de Sharpe.

Los parámetros del caso base se fijaron antes de ver ningún resultado, pero las variantes de robustez se diseñaron después de ver el caso base, así que las tratamos como diagnósticos. En ninguna un modelo supera al pasivo de forma significativa, y en este caso el riesgo es haber dejado de buscar demasiado pronto una regla que sí funcione. El día de ejecución es uno de los supuestos que más mueven el resultado, del tamaño de las diferencias entre modelos (sección 7.1). Quedan fuera la ejecución a la apertura siguiente, que pide un retorno de apertura a apertura y otra serie de costos, y la ejecución a precios promedio del día, que recién se conocen al cerrar la sesión.

Con el pasivo y seis estrategias hay 21 pares por configuración, y entre todas las configuraciones de los capítulos 6 y 7 es de esperar que algún valor p bajo aparezca por azar. La Tabla 16 reúne, para cada variante con test de Sharpe, el valor p mínimo contra el pasivo y los pares entre modelos que bajan de 0.05 neto de costos. Son diez pares en tres variantes, el HAR contra el GBM + VIX los miércoles, el GARCH contra el targeting sin modelo con objetivo de 20% y los ocho pares de los dos GBM contra los otros cuatro modelos a 10 puntos básicos. El único que se repite es el del HAR contra el GBM + VIX, que a 10 puntos básicos vuelve a quedar debajo de 0.05. El valor p más bajo contra el pasivo, 0.066, es el del GBM + VIX a 10 puntos básicos.

Las fricciones también están simplificadas, con costos constantes durante dieciséis años, un fondeo sin llamadas de margen, el efectivo a la tasa de la letra a tres meses y sin impuestos. Costos variables e impuestos probablemente castigan más a quien más opera, así que corregir esas simplificaciones alejaría a los GBM del pasivo antes que acercarlos.

8. Conclusiones

Hong (2026) y Díaz et al. (2024) encuentran que algunos métodos de machine learning pronostican la volatilidad del índice accionario con menor error que el HAR, los árboles con boosting a una semana y a un mes en Hong y la regularización y las redes neuronales a un mes en Díaz et al., y que esa ventaja rinde poco al pasar a una cartera, pero ninguno mide dónde se pierde. Pusimos seis pronósticos y un portafolio con fricciones en un solo protocolo y medimos, paso por paso, cuánto de la ventaja sobrevive y en qué días del mercado el modelo gana su precisión.

El gradient boosting pronostica la volatilidad diaria de SPY con menor QLIKE que EWMA, GARCH y HAR, con diferencias significativas, y también con menor RMSE, y eso sostiene H1. El orden se mantiene con otro proxy, con otros cortes de entrenamiento y con cada pronóstico evaluado un día después de hecho, tal como lo usa la estrategia. Sobre H2 y H3, en cambio, no se encontró evidencia de mejora bajo las reglas probadas, sin que eso demuestre que la mejora sea imposible. El control del objetivo sigue el orden de precisión en el período completo, pero la reducción de exposición la logra cualquier regla de targeting, incluida la que no pronostica. En las muestras, frecuencias, reglas y convenciones implementables para las que realizamos los tests, ninguna diferencia de Sharpe contra el pasivo resulta significativa al 5%. Entre modelos, el único grupo consistente de diferencias significativas al 5% sin corregir por multiplicidad va en contra de los GBM, que con costos de 10 puntos básicos quedan por debajo de cada uno de los otros cuatro.

Aún sin fricciones la ventaja de precisión vale poco, 0.05 puntos porcentuales de riqueza por año entre el GBM y el HAR, y se paga en turnover, porque el GBM opera más de cinco veces lo que opera el EWMA y a 2 puntos básicos eso le cuesta 0.047 de Sharpe, más que su ventaja bruta sobre el EWMA. La ganancia sobre el HAR y el GARCH está además en los días calmos, con el 54% y el 57% en el quintil más calmo, donde cada ajuste del peso parece costar más de lo que corrige. Los mayores valores de Sharpe aparecen al usar información del propio día del retorno o posterior. La aleatorización de signos sugiere que parte de esa ventaja depende de la relación contemporánea entre volatilidad y dirección del retorno.

Nuestro targeting sin modelo, que, como la regla de Moreira y Muir (2017), usa solo la varianza realizada del último mes, tampoco supera al pasivo, en línea con lo que Cederburg et al. (2020) y Liu et al. (2019) encuentran para esa regla construida en tiempo real. Hong (2026) encuentra que la mayor precisión de los árboles se traslada solo en parte al control de la volatilidad, y en nuestra muestra el GBM mejora ese control sin que eso se traduzca en un Sharpe distinguible del pasivo ni de los otros modelos. Como en Bollerslev et al. (2018), los costos reordenan los modelos según cuánto operan, aunque en nuestra muestra el más preciso es el que más opera y más pierde.

La evaluación cubre de 2010 a 2026, un período alcista con episodios de volatilidad cortos, en el que el pasivo rinde un Sharpe de 0.773 con exposición completa a la prima accionaria mientras cada regla de targeting la recorta. Excluir 2020 sube el Sharpe del pasivo a 0.818 casi sin mover el de las estrategias, así que en el año más volátil las estrategias se alejan

menos del pasivo. Una lectura compatible es que la volatilidad se observa después del movimiento que la genera, así que una caída abrupta golpea primero a la cartera y recién después reduce la exposición, y si el rebote llega rápido mientras el pronóstico sigue alto, la estrategia participa poco de él. En una caída persistente el mismo desapalancamiento sí podría ahorrar pérdidas, y las muestras de Harvey et al. (2018), que empiezan en 1926, contienen caídas más largas que la nuestra. En una muestra así el ranking de precisión, que no cambió con ningún corte, probablemente se mantendría, y el targeting tendría más caídas que recortar.

De la maestría usamos sobre todo la econometría de series de tiempo, con la que estimamos GARCH y HAR, la teoría de carteras y la gestión de riesgo, de donde salen el volatility targeting y el ratio de Sharpe, y los derivados, que nos dieron la interpretación del VIX como varianza implícita y la idea de operar la varianza con un swap. Si empezáramos de nuevo, dedicaríamos menos tiempo a las variantes de corte, banda, cap y frecuencia, que confirmaron lo que el caso base ya mostraba, y más a sumar activos, para que la comparación con el pasivo no dependiera de una sola serie, y a usar datos intradía, con los que la varianza realizada se mide con menos ruido. También probaríamos operar la varianza con un swap o con opciones, para que el pronóstico rindiera sin pasar por el signo del retorno, y una banda de no-trade que dependiera del nivel de volatilidad, para que la precisión en los días calmos se tradujera en menos operaciones.

Aprendimos, sobre todo, que la precisión de un pronóstico no se traduce por sí sola en una ganancia económica, y que el día de retraso le cuesta al gradient boosting más precisión que toda su ventaja sobre el HAR. Otras lecciones salieron de corregir versiones anteriores del trabajo. Habíamos tomado de la literatura la orden en el mismo cierre sin discutirla, y la ejecución al cierre siguiente, que adoptamos porque esa orden no es implementable si el pronóstico necesita el cierre, terminó siendo uno de los supuestos que más mueven el resultado. También aprendimos a mirar por separado la precisión, la reducción de exposición y el resultado económico, y esa separación nos permitió ubicar dónde se pierde la ventaja.

Anexos

Anexo A. Hiperparámetros y grilla

Los dos GBM recorren doce combinaciones en cada estimación mensual, con tasas de aprendizaje de 0.025, 0.05 y 0.1 y máximos de 3, 7, 15 y 31 hojas por árbol. Cada combinación puede llegar a 2000 árboles y se detiene tras 50 iteraciones sin mejora del error cuadrático medio de la log-varianza en validación. El bloque de entrenamiento toma el 80% de las observaciones, el embargo es de 22 días y la semilla aleatoria es 42, con ajuste determinista. Los demás parámetros de LightGBM quedan en sus valores por defecto, salvo tres opciones de ejecución, el histograma por filas, el uso de dos hilos y la supresión de mensajes, que no cambian el ajuste.

Anexo B. Derivaciones

Estimador de volatilidad

Si la varianza total de un día resulta no positiva, el término intradiario se reemplaza por el estimador de Parkinson (1980), $p(t) = [\ln(H(t)/L(t))]^2 / (4 \ln 2)$, conservando el término overnight, y si la varianza sigue por debajo de 10^{-8}, se fija en ese valor. En la muestra no ocurrió ninguno de los dos casos.

Modelos de pronóstico

Sean $r(t)$ el retorno logarítmico diario y $v(t) = \sigma^2(t)$ la varianza realizada Garman-Klass más overnight definida en el capítulo 2. La notación $\hat{v}(t+1|t)$ indica el pronóstico de varianza del día siguiente con información hasta el cierre de t. Todos los modelos entregan su raíz cuadrada como pronóstico de volatilidad diaria.

El EWMA actualiza

$$\hat{v}(t+1|t) = 0.94\ \hat{v}(t|t-1) + 0.06\ r(t)^2.$$

Para el GARCH, en la escala porcentual del ajuste, $R(t) = 100\ r(t)$, $\varepsilon(t) = R(t) - \mu$, con μ la media constante estimada, y

$$h(t+1) = \omega + \alpha\ \varepsilon(t)^2 + \beta\ h(t).$$

El pronóstico de volatilidad diaria en decimales es $\sqrt{(h(t+1))} / 100$.

Definimos $m(k,t) = (1/k)\ \Sigma\ v(t-j)$, con j desde 0 hasta k−1. El HAR estima

$$\ln v(t+1) = b_0 + b_1 \ln m(1,t) + b_5 \ln m(5,t) + b_{22} \ln m(22,t) + u(t+1).$$

El GBM sustituye la combinación lineal por una suma de árboles ajustada con pérdida cuadrática sobre $\ln v(t+1)$. Su vector de predictores contiene $\ln m(1,t)$, $\ln m(5,t)$, $\ln m(22,t)$, $\ln v(t-1)$, $r(t)$, las sumas de r de 5 y 22 días, $\ln \max(s^-(t), 10^{-8})$ y $\ln \max(p(t), 10^{-8})$, donde $s^-(t)$ es el promedio de 22 días de r^2 en los días de retorno negativo, con cero en los demás, y $p(t)$ la varianza de Parkinson definida arriba.

El GBM + VIX agrega $z(t) = \ln[(VIX(t)/100)^2 / 252]$, $z(t) - z(t-1)$ y $z(t) - \ln v(t)$. El targeting sin modelo devuelve $\sqrt{(m(21,t))}$.

Si $\hat{L}(t+1|t)$ es el pronóstico de log-varianza de HAR o GBM y s^2 la varianza muestral de sus residuos de validación, la corrección común es

$$\hat{v}(t+1|t) = \exp[\hat{L}(t+1|t) + s^2/2].$$

Pérdidas e inferencia de precisión

Antes de evaluar se aplica el mismo piso, $\max(v, 10^{-8})$, al proxy y al cuadrado de cada pronóstico de volatilidad, porque QLIKE exige varianzas estrictamente positivas. En la muestra el piso no alcanzó a ningún pronóstico ni al proxy principal, y alcanzó a los días del proxy alternativo con retorno de cierre a cierre de hasta 0.01% en valor absoluto, que se cuentan en la Tabla 3 y se conservan en la evaluación con la varianza del piso. Con $q(t) = v(t)/\hat{v}(t|t-1)$ y T días evaluados, la pérdida diaria es $L(t) = q(t) - \ln q(t) - 1$ y

$$QLIKE = (1/T) \Sigma L(t),$$

$$RMSE = \sqrt{((1/T) \Sigma [v(t) - \hat{v}(t|t-1)]^2)}.$$

La robustez de proxy reemplaza $v(t)$ por $r(t)^2$ y conserva los pronósticos. Para cada modelo a, el diferencial es $d(t) = L_a(t) - L_GBM(t)$. El estadístico de Diebold y Mariano es la media de d dividida por $\sqrt{(\hat{\Omega}/T)}$, donde $\hat{\Omega}$ es la varianza de largo plazo estimada con núcleo de Bartlett y el rezago automático de Newey y West (1994). El valor p se calcula a dos colas con la distribución normal estándar.

Estrategia y métricas económicas

Sean $r_s(t)$ el retorno neto diario de la estrategia y $rf(t) = (1 + y(t-1))^{(1/252)} - 1$ el retorno del activo libre de riesgo, con y la tasa anualizada de DGS3MO conocida el día anterior y el spread de 50 puntos básicos convertido a diario con la misma capitalización. Con $e(t) = r_s(t) - rf(t)$ el exceso sobre los T días de la muestra, el ratio de Sharpe es la media de e dividida por su desvío estándar, multiplicada por $\sqrt{252}$. La volatilidad realizada es el desvío estándar de $\ln(1 + r_s(t))$ por $\sqrt{252}$. El drawdown máximo es el mínimo de $W(t)/M(t) - 1$, con W la riqueza acumulada de $(1 + r_s)$ desde $W(0) = 1$ y $M(t)$ el máximo de W hasta t inclusive. Con $\Delta w(t)$ la diferencia entre el peso operado y el peso vigente antes de operar, el turnover anual es 252 veces la media de $|\Delta w(t)|$, y el costo del día es $0.0002\ |\Delta w(t)|$, con 0.0005 y 0.0010 en las sensibilidades. Con $\sigma_{21}(t)$ la volatilidad anualizada de los últimos 21 retornos logarítmicos de la estrategia, el vol-of-vol es la raíz de la media de $(\sigma_{21}(t) - 0.10)^2$, y el desvío del objetivo es la volatilidad realizada de toda la muestra menos 0.10. Las colas son los cinco peores valores de r_s, su asimetría y su curtosis en exceso.

La regresión de spanning es $e_s(t) = \alpha + \beta\ e_m(t) + u(t)$, con e_s el exceso de la estrategia y e_m el exceso del pasivo, que coincide con el de SPY salvo el costo inicial en la serie neta. El error estándar de α es el de Newey y West (1987) con núcleo de Bartlett, con el rezago elegido por la regla automática de Newey y West (1994) aplicada a la serie de

influencia de α, y el valor p se calcula a dos colas con la distribución normal. El alfa anual es 252 α.

La diferencia de ratios de Sharpe entre dos estrategias se prueba con el estadístico studentizado de Ledoit y Wolf (2008), la diferencia de los dos ratios diarios dividida por su error estándar, obtenido por el método delta con la varianza de largo plazo de los primeros dos momentos de los dos excesos. El valor p sale de un bootstrap estacionario por bloques (Politis y Romano, 1994) de B = 1000 réplicas con semilla fija, en lugar del bootstrap circular por bloques de Ledoit y Wolf, con largo de bloque elegido con la regla de Politis y White (2004), con la corrección de Patton et al. (2009). La regla se aplica a los excesos al cuadrado de cada una de las dos series y se usa el mayor de los dos largos, redondeado hacia arriba. Si k réplicas tienen un estadístico recentrado que iguala o supera en valor absoluto al observado, el valor p es (k + 1)/(B + 1). Las dos series entran pareadas, de modo que cada réplica mueve a las dos juntas, y la diferencia que muestran las tablas es la diaria multiplicada por √252.

Utilidad realizada de los pronósticos

Con $\rho(t) = \sqrt{(v(t)/\hat{v}(t|t-1))}$, la utilidad realizada anual de Bollerslev et al. (2018) se calcula como

$$U = (SR^2/\gamma)\ (1/T)\ \Sigma\ [\rho(t) - \rho(t)^2/2],$$

con SR = 0.4 anual y γ = 2. Como SR es anual y ρ(t) no tiene unidades, U queda directamente en fracción de riqueza por año. Un pronóstico perfecto tiene ρ(t) = 1 y entrega $SR^2/(2\gamma) = 0.04$, equivalente a 4% de riqueza por año.

Anexo C. Repositorio y reproducibilidad

El código, los datos congelados y todas las tablas y gráficos del documento están en el repositorio público: https://github.com/EzeTelias95/spy-volatility-targeting. Un solo comando reconstruye la base desde la copia congelada, corre la evaluación cronológica de los seis modelos en los tres cortes de entrenamiento y el backtest en cada configuración de los capítulos 5 a 7, incluidos los oráculos, y escribe las 19 tablas y los 4 gráficos con sus títulos y fuentes. Cada corrida deja un manifiesto con la versión del código y la huella de los datos crudos, y el backtest rechaza combinar pronósticos que salgan de otra copia de los datos.

El repositorio separa la descarga y construcción de la base, los seis modelos, el backtest, la evaluación, el reporte y las pruebas automáticas. Los modelos comparten una misma interfaz con tres operaciones, estimar con toda la historia, incorporar un día nuevo y pronosticar el siguiente, y el paquete de evaluación reúne las pérdidas, los tests estadísticos, el recorrido cronológico de los modelos, los oráculos y la capacidad.

El código está escrito en Python 3.12 con las versiones de las dependencias fijadas, con pandas y numpy para datos y cálculo, pyarrow para los resultados intermedios, yfinance para la descarga, arch para el GARCH, LightGBM para el gradient boosting, matplotlib para los gráficos y pytest para las pruebas. El EWMA, el HAR y el targeting sin modelo están

implementados a mano. Preferimos un backtest propio a las bibliotecas de backtest disponibles porque estas están orientadas a órdenes y a varios activos, mientras que esta estrategia es una serie de pesos sobre un activo cuyo riesgo central es la alineación temporal entre señal y ejecución. Un backtest propio permite fijar la ecuación de ejecución de forma explícita y comprobable, aplicar la banda de no-trade sobre el peso desplazado y activar y desactivar cada fricción por separado para la tabla de atribución.

Las 221 pruebas automáticas verifican los cálculos, no los resultados. El estimador de volatilidad se compara con un cálculo a mano en un día normal, en una fecha ex-dividendo, en un día con varianza Garman-Klass no positiva y en un día plano. Para el GBM se comprueba que los predictores usan solo datos hasta el día de decisión, que el target está un día adelante y que la validación queda separada del entrenamiento por el embargo. Para el HAR se comprueba que recupera por simulación las pendientes que generaron la serie, y para los dos que la corrección lognormal sale de los residuos de validación. Para el EWMA, el HAR, el GBM y el targeting sin modelo se verifica que estimar con toda la historia deja el mismo estado que haber incorporado los días uno por uno, y para el GARCH que estimar, actualizar y volver a estimar coincide con una estimación nueva. La alineación del backtest se prueba con pesos conocidos sobre tres fechas, y se comprueba que el peso decidido con el cierre de t devenga el retorno de t+2, que el retorno bruto coincide con la suma calculada a mano de SPY, efectivo y fondeo con peso menor, igual y mayor que uno, y que el peso desplazado sigue a los retornos relativos. El resto de las pruebas cubre la banda, el cap como disparador, las frecuencias semanal y mensual sin usar pronósticos ni retornos futuros, las métricas y la regresión de spanning contra valores a mano, la reproducibilidad del test de diferencia de Sharpe, y que la aleatorización de signos conserva los cocientes intradiarios y la magnitud de cada movimiento centrado.

Yahoo Finance no conserva las versiones históricas de sus series. Los precios ajustados se revisan con cada dividendo y cada split, así que una descarga de hoy no reproduce exactamente una de hace un año. Por eso congelamos la descarga cruda del 24 de agosto de 2026 y todas las tablas y gráficos del documento salen de esa copia, y los datos derivados se recalculan a partir de ella. Antes de construir la base verificamos que en cada fila el máximo no sea menor que la apertura ni que el cierre, y que el mínimo no sea mayor que ninguno de los dos. Una fila que lo viole interrumpe la construcción y queda registrada, porque descartarla partiría en dos el retorno y el salto overnight del día siguiente. En la copia congelada no hubo ninguna.

Anexo D. Tablas adicionales

Tabla 13: Colas y actividad de trading en el caso base, bruto y neto de costos

Estrategia	Sharpe bruto	Sharpe neto	Costo en Sharpe	Peor día	Asimetría	Curtosis en exceso	Días operados por año	Cambio medio de peso (pp)
Pasivo	0.773	0.773	0.000	-10.9%	-0.33	12.01	0.1	100.00
Trailing 21 días	0.742	0.735	0.007	-4.6%	-0.77	3.12	45.7	8.34
EWMA	0.746	0.738	0.008	-4.8%	-0.85	3.82	52.6	7.98
GARCH(1,1)	0.758	0.744	0.014	-4.1%	-0.82	3.22	77.7	8.73

Estrategia	Sharpe bruto	Sharpe neto	Costo en Sharpe	Peor día	Asimetría	Curtosis en exceso	Días operados por año	Cambio medio de peso (pp)
HAR-RV	0.791	0.760	0.031	-3.6%	-0.70	2.26	129.6	11.73
GBM	0.779	0.732	0.047	-3.8%	-0.69	2.21	161.3	14.54
GBM + VIX	0.779	0.732	0.047	-3.7%	-0.66	1.86	160.2	14.41

Fuente: elaboración propia en base a datos de Yahoo Finance y FRED.

Tabla 14: Diferencia de Sharpe entre pares de estrategias, bruta y neta de costos

Par	Dif. Sharpe, bruto	p, bruto	Dif. Sharpe, neto	p, neto
EWMA vs GARCH(1,1)	-0.012	0.64	-0.006	0.81
EWMA vs HAR-RV	-0.044	0.38	-0.021	0.67
EWMA vs GBM	-0.033	0.58	0.006	0.93
EWMA vs GBM + VIX	-0.033	0.59	0.006	0.92
EWMA vs Trailing 21 días	0.004	0.91	0.003	0.93
EWMA vs Pasivo	-0.027	0.80	-0.035	0.75
GARCH(1,1) vs HAR-RV	-0.032	0.45	-0.015	0.71
GARCH(1,1) vs GBM	-0.021	0.68	0.012	0.82
GARCH(1,1) vs GBM + VIX	-0.021	0.72	0.012	0.84
GARCH(1,1) vs Trailing 21 días	0.016	0.69	0.009	0.83
GARCH(1,1) vs Pasivo	-0.015	0.89	-0.029	0.79
HAR-RV vs GBM	0.011	0.74	0.027	0.39
HAR-RV vs GBM + VIX	0.011	0.78	0.027	0.52
HAR-RV vs Trailing 21 días	0.049	0.22	0.025	0.53
HAR-RV vs Pasivo	0.017	0.88	-0.013	0.91
GBM vs GBM + VIX	0.000	1.00	0.000	1.00
GBM vs Trailing 21 días	0.037	0.42	-0.003	0.96
GBM vs Pasivo	0.006	0.96	-0.041	0.74
GBM + VIX vs Trailing 21 días	0.037	0.48	-0.003	0.95
GBM + VIX vs Pasivo	0.006	0.95	-0.041	0.72
Trailing 21 días vs Pasivo	-0.031	0.78	-0.038	0.73

Fuente: elaboración propia en base a datos de Yahoo Finance y FRED.

Tabla 15: Diagnósticos del cap, de las reglas de salida y de la capacidad

Medida	Trailing 21 días	EWMA	GARCH(1,1)	HAR-RV	GBM	GBM + VIX
Días sobre el cap, decisión semanal	13	21	8	22	31	36
Peso máximo, decisión semanal	1.51	1.54	1.51	1.51	1.51	1.51
Días sobre el cap, decisión mensual	54	65	0	36	3	2
Peso máximo, decisión mensual	1.52	1.59	1.45	1.54	1.51	1.51
Días con el cap activo, objetivo 10%	2.9%	3.0%	0.5%	1.8%	2.6%	2.8%
Días con el cap activo, objetivo 15%	26.7%	21.6%	19.3%	21.2%	25.6%	26.0%
Días con el cap activo, objetivo 20%	55.4%	55.1%	51.2%	50.5%	54.8%	54.9%

Medida	Trailing 21 días	EWMA	GARCH(1,1)	HAR-RV	GBM	GBM + VIX
Retorno medio de SPY fuera del mercado, corte de vol 30% (pb)	17.3	19.1	18.0	36.2	34.1	27.2
Retorno medio de SPY dentro del mercado, corte de vol 30% (pb)	5.4	5.2	5.2	4.3	4.5	4.7
Retorno medio de SPY fuera del mercado, corte de vol 20% (pb)	12.9	11.0	9.5	12.7	10.2	13.3
Retorno medio de SPY dentro del mercado, corte de vol 20% (pb)	4.4	4.7	5.0	4.3	4.9	4.3
Capacidad mediana (miles de millones de dólares)	3.38	3.45	3.36	2.57	2.15	2.14

Fuente: elaboración propia en base a datos de Yahoo Finance y FRED.

Tabla 16: Tests de diferencia de Sharpe neta por variante, p mínimo contra el pasivo y pares entre modelos con p menor que 0.05

Variante	p mínimo contra el pasivo	Pares entre modelos con p < 0.05
Caso base	0.723 (GBM + VIX)	ninguno
Entrenamiento hasta 2008	0.816 (GBM)	ninguno
Entrenamiento hasta 2012	0.655 (GARCH(1,1))	ninguno
2010-2017	0.418 (GBM)	ninguno
2018-2026	0.585 (EWMA)	ninguno
Sin 2020	0.256 (GBM + VIX)	ninguno
Decisión semanal, lunes	0.639 (EWMA)	ninguno
Decisión semanal, martes	0.784 (EWMA)	ninguno
Decisión semanal, miércoles	0.227 (GBM + VIX)	HAR-RV vs GBM + VIX (0.040)
Decisión semanal, jueves	0.609 (EWMA)	ninguno
Decisión semanal, viernes	0.503 (HAR-RV)	ninguno
Decisión mensual	0.503 (HAR-RV)	ninguno
Vol objetivo 15%	0.740 (GBM + VIX)	ninguno
Vol objetivo 20%	0.524 (GARCH(1,1))	GARCH(1,1) vs Trailing 21 días (0.038)
Sin cap	0.727 (GBM)	ninguno
Regla por varianza	0.206 (GBM + VIX)	ninguno
Corte de vol 30%	0.328 (HAR-RV)	ninguno
Corte de vol 20%	0.253 (GBM + VIX)	ninguno
Pronóstico a dos días	0.730 (Trailing 21 días)	ninguno
5 bps	0.356 (GBM + VIX)	ninguno
10 bps	0.066 (GBM + VIX)	EWMA vs GBM (0.004), HAR-RV vs GBM (0.005), GBM vs Trailing 21 días (0.005), GBM + VIX vs Trailing 21 días (0.007), EWMA vs GBM + VIX (0.009), GARCH(1,1) vs GBM (0.009), GARCH(1,1) vs GBM + VIX (0.012), HAR-RV vs GBM + VIX (0.024)

Variante	p mínimo contra el pasivo	Pares entre modelos con p < 0.05
Orden al mismo cierre con cap, banda y costos	0.818 (HAR-RV)	ninguno

Fuente: elaboración propia en base a datos de Yahoo Finance y FRED.

Tabla 17: QLIKE del pronóstico a tiempo, con un día de atraso y a dos días, 4146 días desde el 5 de enero de 2010

Modelo	QLIKE a tiempo	QLIKE con un día de atraso	Aumento por el atraso	DM vs GBM, con atraso	p DM, con atraso	QLIKE a dos días	Recuperado por el pronóstico a dos días	p, dos días contra atrasado
Trailing 21 días	0.524	0.569	8.6%	5.84	<0.001	0.569	0.0%	1.00
EWMA	0.497	0.546	9.9%	5.04	<0.001	0.546	0.0%	1.00
GARCH(1,1)	0.443	0.487	9.8%	3.77	<0.001	0.486	3.0%	0.14
HAR-RV	0.419	0.458	9.4%	2.24	0.03	0.454	11.8%	0.02
GBM	0.378	0.440	16.3%			0.435	7.2%	0.43
GBM + VIX	0.352	0.410	16.4%	-3.90	<0.001	0.407	5.3%	0.46

Fuente: elaboración propia en base a datos de Yahoo Finance.

Tabla 18: Oráculos con información futura y aleatorización de signos, orden al mismo cierre, 100 réplicas, 4127 días hasta el 1 de junio de 2026

Estrategia	Sharpe neto	Exceso sobre el pasivo	Exceso con signos aleatorizados	Diferencia entre ambos excesos
Oráculo diario	2.062	1.273	0.389	0.885
Oráculo de 21 días	1.835	1.046	0.304	0.743
Trailing 21 días	0.809	0.021	0.228	-0.208
EWMA	0.782	-0.006	0.217	-0.223
GARCH(1,1)	0.801	0.012	0.235	-0.222
HAR-RV	0.835	0.047	0.254	-0.207
GBM	0.809	0.020	0.259	-0.239
GBM + VIX	0.802	0.013	0.270	-0.256
Pasivo	0.788	0.000	0.000	0.000

Fuente: elaboración propia en base a datos de Yahoo Finance y FRED.

Tabla 19: Retorno medio de SPY por quintil de volatilidad, en puntos básicos

Quintil	Vol realizada del día	Oráculo de 21 días	Pronóstico del GBM
Q1 (más calmo)	9.7	15.2	1.6
Q2	14.8	15.1	4.8
Q3	14.3	8.9	7.1
Q4	5.3	2.8	7.3
Q5 (más volátil)	-14.3	-12.3	9.0

Fuente: elaboración propia en base a datos de Yahoo Finance.

Anexo E. Nota sobre convenciones

Salvo aclaración, Sharpe es el ratio de Sharpe anualizado neto de costos, el pasivo es SPY comprado el primer día fuera de muestra y mantenido, y la muestra es la del caso base. Los pronósticos se evalúan sobre 4147 días, del 4 de enero de 2010 al 30 de junio de 2026, y

las estrategias sobre 4146 días de retorno, desde el 5 de enero de 2010. La Tabla 17 evalúa sobre esos 4146 días, porque el pronóstico atrasado no existe para el primer día, y por eso su QLIKE a tiempo difiere en la tercera cifra decimal del de la Tabla 2 para el GARCH y el GBM. En la Tabla 11, la fila del peso aplicado al retorno del día de la decisión corre sobre 4146 días, del 4 de enero de 2010 al 29 de junio de 2026, y la de la orden al mismo cierre sin fricciones sobre 4147 días desde el 4 de enero de 2010, porque con el rezago cero el último día queda sin peso y con el rezago uno no se pierde ninguno. Las demás filas corren sobre los 4146 días del caso base. Los valores de la Tabla 18 no son comparables fila por fila con los del caso base, porque corren con otra convención de orden y otra muestra, y en esa tabla el pasivo no paga el costo inicial, lo que no cambia su tercera cifra decimal.

Los números usan punto decimal. Los pronósticos y la volatilidad realizada son desvíos diarios, y se anualizan por $\sqrt{252}$ solo para reportar. QLIKE y RMSE se calculan sobre varianzas, y RMSE se muestra multiplicado por diez mil. El vol-of-vol está en puntos porcentuales con dos decimales, el turnover en veces el capital por año y los costos de transacción en puntos básicos por operación sobre el monto operado. Los valores p de diferencia de Sharpe son los del test pareado de Ledoit y Wolf (2008) a dos colas, y los de precisión los del test de Diebold y Mariano (1995) contra el GBM base, salvo la última columna de la Tabla 17, que compara el pronóstico a dos días de cada modelo con su propio pronóstico atrasado.

Bibliografía

Andersen, T. G., Bollerslev, T., Christoffersen, P. F. y Diebold, F. X. (2006). Volatility and correlation forecasting. En G. Elliott, C. W. J. Granger y A. Timmermann (Eds.), *Handbook of economic forecasting* (Vol. 1, pp. 777-878). Elsevier. https://doi.org/10.1016/S1574-0706(05)01015-3

Bollerslev, T. (1986). Generalized autoregressive conditional heteroskedasticity. *Journal of Econometrics*, *31*(3), 307-327. https://doi.org/10.1016/0304-4076(86)90063-1

Bollerslev, T. (1987). A conditionally heteroskedastic time series model for speculative prices and rates of return. *Review of Economics and Statistics*, *69*(3), 542-547. https://doi.org/10.2307/1925546

Bollerslev, T., Hood, B., Huss, J. y Pedersen, L. H. (2018). Risk everywhere: Modeling and managing volatility. *Review of Financial Studies*, *31*(7), 2729-2773. https://doi.org/10.1093/rfs/hhy041

Cederburg, S., O'Doherty, M. S., Wang, F. y Yan, X. (2020). On the performance of volatility-managed portfolios. *Journal of Financial Economics*, *138*(1), 95-117. https://doi.org/10.1016/j.jfineco.2020.04.015

Corsi, F. (2009). A simple approximate long-memory model of realized volatility. *Journal of Financial Econometrics*, *7*(2), 174-196. https://doi.org/10.1093/jjfinec/nbp001

Díaz, J. D., Hansen, E. y Cabrera, G. (2024). Machine-learning stock market volatility: Predictability, drivers, and economic value. *International Review of Financial Analysis*, *94*, Artículo 103286. https://doi.org/10.1016/j.irfa.2024.103286

Diebold, F. X. y Mariano, R. S. (1995). Comparing predictive accuracy. *Journal of Business & Economic Statistics*, *13*(3), 253-263. https://doi.org/10.1080/07350015.1995.10524599

Garman, M. B. y Klass, M. J. (1980). On the estimation of security price volatilities from historical data. *Journal of Business*, *53*(1), 67-78. https://doi.org/10.1086/296072

Harvey, C. R., Hoyle, E., Korgaonkar, R., Rattray, S., Sargaison, M. y Van Hemert, O. (2018). The impact of volatility targeting. *Journal of Portfolio Management*, *45*(1), 14-33. https://doi.org/10.3905/jpm.2018.45.1.014

Hong, X. (2026). *Forecasting and managing volatility with machine learning* [Documento de trabajo]. SSRN. https://doi.org/10.2139/ssrn.6277518

J.P. Morgan/Reuters. (1996). *RiskMetrics technical document* (4.ª ed.).

Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q. y Liu, T.-Y. (2017). LightGBM: A highly efficient gradient boosting decision tree. *Advances in Neural Information Processing Systems*, *30*, 3146-3154.

Ledoit, O. y Wolf, M. (2008). Robust performance hypothesis testing with the Sharpe ratio. *Journal of Empirical Finance*, *15*(5), 850-859. https://doi.org/10.1016/j.jempfin.2008.03.002

Liu, F., Tang, X. y Zhou, G. (2019). Volatility-managed portfolio: Does it really work? *Journal of Portfolio Management*, *46*(1), 38-51. https://doi.org/10.3905/jpm.2019.1.107

Lolic, M. (2025). Tree-based methods of volatility prediction for the S&P 500 index. *Computation*, *13*(4), Artículo 84. https://doi.org/10.3390/computation13040084

López de Prado, M. (2018). *Advances in financial machine learning*. Wiley.

Moreira, A. y Muir, T. (2017). Volatility-managed portfolios. *Journal of Finance*, *72*(4), 1611-1644. https://doi.org/10.1111/jofi.12513

Newey, W. K. y West, K. D. (1987). A simple, positive semi-definite, heteroskedasticity and autocorrelation consistent covariance matrix. *Econometrica*, *55*(3), 703-708. https://doi.org/10.2307/1913610

Newey, W. K. y West, K. D. (1994). Automatic lag selection in covariance matrix estimation. *Review of Economic Studies*, *61*(4), 631-653. https://doi.org/10.2307/2297912

Parkinson, M. (1980). The extreme value method for estimating the variance of the rate of return. *Journal of Business*, *53*(1), 61-65. https://doi.org/10.1086/296071

Patton, A. J. (2011). Volatility forecast comparison using imperfect volatility proxies. *Journal of Econometrics*, *160*(1), 246-256. https://doi.org/10.1016/j.jeconom.2010.03.034

Patton, A. J., Politis, D. N. y White, H. (2009). Correction to "Automatic block-length selection for the dependent bootstrap" by D. Politis and H. White. *Econometric Reviews*, *28*(4), 372-375. https://doi.org/10.1080/07474930802459016

Politis, D. N. y Romano, J. P. (1994). The stationary bootstrap. *Journal of the American Statistical Association*, *89*(428), 1303-1313. https://doi.org/10.1080/01621459.1994.10476870

Politis, D. N. y White, H. (2004). Automatic block-length selection for the dependent bootstrap. *Econometric Reviews*, *23*(1), 53-70. https://doi.org/10.1081/ETC-120028836

Yang, D. y Zhang, Q. (2000). Drift-independent volatility estimation based on high, low, open, and close prices. *Journal of Business*, *73*(3), 477-492. https://doi.org/10.1086/209650